석사학위논문

사전학습 시계열 모델의 금융 수익률 예측구간: 오차의 출처와 재학습 없는 사후보정

- 실측 기반 합성 데이터 통제 실험과 미국·한국 대형주 실증 -

Prediction Intervals of Pretrained Time Series Foundation Models for Financial Returns: Sources of Error and Training-Free Post-hoc Calibration

- Controlled Experiments on Synthetic Data Calibrated to Real Markets and Evidence from U.S. and Korean Large-Cap Stocks -

김승민

한양대학교 인공지능융합대학원

2027년 2월

차 례

국문요지 v

제 1 장 서론 1
1.1 연구 배경 1
1.2 연구 질문 2
1.3 연구 방법 개요 2
1.4 주요 결과와 기여 4
1.5 논문 구성 5

제 2 장 관련 연구 6
2.1 금융 수익률의 특성 6
2.2 시계열 파운데이션 모델 7
2.3 금융에서의 TSFM 평가 8
2.4 합성 데이터를 이용한 진단 9
2.5 예측구간의 평가와 사후보정 10
2.6 본 연구의 위치 11

제 3 장 연구 설계 12
3.1 예측 문제 12
3.2 실측 기반 합성 데이터 13
3.2.1 설계 원칙 13
3.2.2 금융 데이터의 세 가지 특성 14
3.2.3 실제 10 종목에서 특성 강도 측정 15
3.2.4 단계 규칙과 확정 단계값 16
3.2.5 생성식 17
3.2.6 생성 검증 19
3.3 실제 주식 데이터 20
3.4 비교 모델 21
3.5 사후보정 22
3.5.1 ACI-CQR 22
3.5.2 대조군 22
3.6 평가 지표와 가설 검정 23
3.6.1 지표 23
3.6.2 연구 질문과 가설 24
3.7 사전등록과 검산 25

제 4 장 금융 특성이 예측구간에 미치는 영향 (RQ1) 26
4.1 실험 절차 점검 26
4.2 기준 상태(L1)의 보정 전 커버리지 27
4.3 특성 강도에 따른 커버리지 변화 (H1~H3b) 29

4.3.1 변동성 군집(H1)의 영향 31
4.3.2 두꺼운 꼬리(H2)의 영향 32
4.3.3 국면 전환 빈도(H3a)와 크기(H3b)의 영향 33
4.4 특성 간 결손 비교 (H4) 34
4.5 소결 37

제 5 장 실제 주가에서의 예측구간 평가 (RQ2) 38
5.1 보정 전 커버리지 39
5.2 과거변동(RW) 대비 분위수 손실 (H6) 41
5.3 모델 공개 이후 기간 점검 43
5.4 합성 데이터 실험과 실증 결과의 대응 44
5.5 탐색 분석: 예측구간과 투자 성과 44
5.5.1 방향 매매 46
5.5.2 변동성 목표 비중 조절 48
5.5.3 VaR 10% 백테스트 50
5.5.4 해석과 한계 52
5.6 소결 53

제 6 장 사후보정을 통한 커버리지 복원 (RQ3) 54
6.1 합성 데이터에서의 보정 결과 55
6.2 실제 주식에서의 보정 결과 57
6.3 보정에 따른 구간 폭 변화 58
6.4 일괄 확대 대조군과의 비교 59
6.5 GARCH-t 비정상 값에 대한 민감도 분석 60
6.6 실무적 의미 60
6.7 소결 61

제 7 장 결론 62
7.1 연구 요약 62
7.2 실무적 시사점 64
7.3 한계 65
7.4 향후 연구 66
7.5 맺음말 66

참고문헌 67

부록 A. 사전등록 및 재현 정보 69
A.1 사전등록 동결과 이탈 기록 69
A.2 실행 환경 및 패키지 버전 69

부록 B. 특성 강도 비교(L5 - L3) 70

부록 C. 종목별 실제 커버리지 71

ABSTRACT 73

표 차례

표 2-1. 관련 연구 비교 11

표 3-1. 예측 문제 설정 12

표 3-2. 실제 10 종목의 특성 측정값 16

표 3-3. 합성 데이터 단계값 17

표 3-4. 합성 데이터 생성 검증 19

표 3-5. 실제 주식 데이터 20

표 3-6. 비교 모델 21

표 3-7. 가설과 검정 24

표 4-1. 기준 상태(L1)와 전체 시나리오의 보정 전 커버리지 27

표 4-2. 특성을 가장 강하게 설정했을 때(L5)의 커버리지 변화 (L5 − L1, %p) 30

표 4-3. 분산이 같은 정규분포 기반 구간을 t 분포 데이터에 적용했을 때의 이론 커버리지 (%) 32

표 4-4. 고강도(L4 · L5)에서 특성별 결손 (80% − 커버리지, %p; 양수 = 구간이 좁음) 34

표 5-1. 실제 10 종목의 보정 전 커버리지 (채점 17,700 건) 39

표 5-2. RW 대비 분위수 손실 개선율 (양수 = TSFM 이 나음) 41

표 5-3. 모델 공개 이후 기간의 결과 43

표 5-4. 방향 매매 결과 (10 종목 동일비중 포트폴리오) 46

표 5-5. 비중 조절(변동성 목표 1%) 결과 (비용 반영, 원래 구간 / 보정 구간) 49

표 5-6. 위험 한도(VaR 10%) 백테스트 (보정 전 → 보정 후) 51

표 6-1. 합성 데이터의 보정 전후 커버리지 (17 개 시나리오의 범위) 55

표 6-2. 실제 10 종목의 보정 전후 커버리지 57

표 6-3. GARCH-t 비정상 값 2 건 대체 전후 비교 (합성 데이터 17 개 시나리오 전체) 60

표 7-1. 연구 질문별 가설 판정과 발견 62

표 B-1. 특성을 L3 에서 L5 로 강하게 설정했을 때의 커버리지 변화 (L5 − L3, %p) 70

표 C-1. 미국 종목별 보정 전 커버리지 (%) 71

표 C-2. 한국 종목별 보정 전 커버리지 (%) 72

그림 차례

그림 3-1. 실제 주식의 하루 수익률(2019-07 ~ 2021-06) 14

그림 3-2. 같은 난수로 만든 계열의 L1과 축별 L5..... 18

그림 4-1. 합성 데이터 시나리오별 보정 전 커버리지(%, 시나리오당 100계열 × 채점 60일) 29

그림 4-2. 특성 강도에 따른 커버리지 변화(L1 대비, %p) 31

그림 5-1. 실제 10종목의 보정 전 커버리지(2017~2026, 17,700건) 40

그림 5-2. 과거변동(RW) 대비 분위수 손실 개선율(H6) 42

그림 5-3. 10종목 동일비중 포트폴리오의 누적 수익(2017-02~2026-09, 탐색 분석) 52

그림 6-1. 사후보정(ACI-CQR) 전후 커버리지 56

국문요지

시계열 파운데이션 모델(TSFM)은 추가 학습 없이 예측구간을 함께 내므로 금융 위험 관리에 쓰일 가능성이 크지만, 금융 수익률에서 그 구간이 명목 커버리지를 충족하는지는 체계적으로 검증되지 않았다. 본 연구는 TSFM의 80% 예측구간이 명목 수준에서 벗어나는 원인에 대하여, 이것이 금융 데이터의 특성에서 기인하는지 혹은 모델과 사용 설정에서 기인하는지를 진단하고, 실제 주식에서의 성능을 평가한 후 그 오차를 재학습 없는 사후보정으로 교정할 수 있는지를 검증하였다.

실제 미국·한국 대형주 10종목에서 측정한 변동성 군집, 두꺼운 꼬리, 국면 전환 빈도와 크기를 기준치로 삼아 합성 데이터 17개 시나리오를 만들고, 공통 난수로 특성 하나씩만 바꾸었다. TSFM 4종(Chronos-T5, Chronos-2, TimesFM-2.5, Moirai-2.0)을 과거 길이(21·252일)와 입력 형태(수익률·가격)의 4개 조건에서 다음 날 로그수익률에 대해 평가하고, 같은 절차를 2017~2026년 실제 10종목(24,132건)에 적용하였다. 모든 설정과 검정은 실행 전에 동결하였다.

특성이 없는 합성 데이터에서 이미 TSFM 커버리지는 14~88%로 모델 및 설정마다 다르게 나타났으며, 특성을 실제 종목 중 가장 강한 수준(L5)으로 설정하더라도 대부분의 변화 폭은 3%p 이내였다. 특성별로는 변동성 군집만이 일부 조건에서 커버리지를 하락시켰고, 두꺼운 꼬리와 잦은 국면 전환 특성은 오히려 커버리지를 상승시켰는데, 이러한 상승은 첨도가 높은 분포에서 분산 기반 80% 구간이 갖는 수학적 성질로 설명된다. 실제 주가의 커버리지는 특성 없는 합성 데이터의 커버리지와 평균 1.0%p(붕괴한 2개 조건 제외, 전체 1.2%p) 차이를 보였다. 실제 주식에서 분위수 손실은 16개 조건 중 13개에서 과거 변동성 기반 정규분포(RW)보다 컸다. 적응형 콘포멀 분위수 보정(ACI-CQR)은 합성 340개, 실제 19개 모델·조건 모두에서 커버리지를 80%로 복원하였으며, 그에 상응하여 예측구간의 폭은 이상적인 구간보다 6~48% 넓어졌다. 탐색 분석

에서 보정된 구간은 변동성 목표 전략과 VaR 백테스트에서 의도한 위험 수준을 회복시켰다.

이러한 결과는 금융 수익률에 대한 TSFM 예측구간의 신뢰성이 금융 데이터의 특성보다 모델과 입력 설정에 의해 좌우되며, 실측 기반 합성 데이터 실험으로 실제 주식에서의 커버리지를 미리 가늠할 수 있음을 보여 준다. 분포의 정확도는 단순 기준 모형을 넘지 못하였고, 가장 나은 조건(Chronos-T5를 제외한 세 모델의 1년 · 수익률)에서 같은 수준에 도달하였다. 따라서 현재의 TSFM은 수익률 예측기보다는 입력 설정을 점검하고 재학습 없는 사후보정을 거친 위험 측정 도구로 활용하는 것이 적절하다.

주제어: 시계열 파운데이션 모델, 예측구간, 커버리지, 합성 데이터 통제 실험, 콘포멀 예측, 주가 수익률

제 1 장 서론

1.1 연구 배경

시계열 파운데이션 모델(time series foundation model, TSFM)은 대량의 시계열로 미리 학습해 두고, 새로운 데이터에는 추가 학습 없이 바로 예측을 내는 모델이다. Chronos, TimesFM, Moirai 같은 모델이 2024년 이후 잇달아 공개되었고, 최근에는 Chronos-2, TimesFM-2.5, Moirai-2.0으로 개선판이 나왔다. 이 모델들은 숫자 하나(점 예측)만이 아니라 "내일 값이 이 범위에 80% 확률로 들어간다" 같은 예측구간, 즉 확률 예측을 함께 낸다.

금융에서는 점 예측과 함께 예측구간도 중요한 역할을 한다. 일별 주가 수익률의 방향은 예측하기 어렵지만, 변동성은 지속되는 성질이 있어 내일 얼마나 크게 움직일지는 어느 정도 예측할 수 있고, 이것이 위험 한도(VaR), 포지션 크기 조절, 손절 기준 같은 실무 위험 관리의 기초가 된다. 이때 중요한 것은 구간이 명목 수준을 충족하는가이다. 80% 구간이라고 했으면 실제로 열 번 중 여덟 번은 그 안에 들어와야 한다. 들어오는 비율(커버리지)이 60%라면 위험을 과소평가한 것이고, 95%라면 필요 이상으로 보수적인 것이다.

그런데 금융 분야의 TSFM 연구는 주로 점 예측의 정확도를 비교해 왔다. Rahimikia 외(2025)는 여러 나라의 일별 주식 수익률에서 Chronos · TimesFM을 그대로 쓰면 성과가 나쁘다고 보고했고, Noguer i Alonso와 Franklin(2026)은 미국 대형주 5종목에서 TSFM이 처음부터 학습한 신경망보다 대체로 낫지만 랜덤워크 대비 이득은 작다고 보고하였다. 두 연구 모두 예측구간의 커버리지는 평가하지 않았다. 한편 FinStressTS(Sun 외, 2026)는 금융 특성을 하나씩 조절한 합성 데이터로 예측 모델의 약점을 진단하는 방법을 제시했지만, 사전학습 TSFM의 제로샷 예측구간을 대상으로 하지는 않았다.

따라서 사전학습 TSFM의 금융 예측구간이 명목 커버리지를 충족하는지, 미달 또는 초과가 발생한다면 그 원인이 금융 시계열의 고유 특성(변동성 군집,

두꺼운 꼬리, 국면 전환)에 있는지 혹은 모델 및 입력 설정에 있는지, 나아가 재학습 없는 사후보정으로 이를 교정할 수 있는지에 대해서는 체계적인 검증이 필요한 시점이다.

1.2 연구 질문

본 연구는 세 질문에 답한다.

- RQ1 (진단): 금융 데이터의 특성(변동성 군집, 두꺼운 꼬리, 국면 전환의 빈도와 크기)이 강해질수록 TSFM 80% 예측구간의 커버리지가 떨어지는가, 아니면 모델과 입력 설정에서 이미 오차가 발생하는가? 특성 중에서는 어떤 것이 가장 불리한가?
- RQ2 (실증 평가): 실제 미국 · 한국 대형주에서 TSFM 예측구간의 커버리지와 분포 정확도는 어떠하며, 단순 기준 모형(과거 변동성 기반 정규분포, RW)보다 나은가?
- RQ3 (처방): 모델을 재학습하지 않는 온라인 사후보정(ACI-CQR)으로 커버리지를 80%로 복원할 수 있는가? 그에 수반되는 구간 폭의 확대는 어느 정도인가?

1.3 연구 방법 개요

RQ1은 합성 데이터 실험으로 답한다. 실제 10종목에서 측정한 특성 강도를 기준치로 삼아 합성 데이터 17개 시나리오(특성 없음 1개 + 4개 특성 × 4단계)를 만들고, 같은 난수와 같은 평균 변동 크기를 쓰되 특성 하나만 바꾸어 그 영향을 분리하였다. 데이터를 만든 참 분포를 알기 때문에 오라클 모형으로 채점 절차를 검증할 수 있다.

RQ2는 실제 주가 실증으로 답한다. 미국 5종목(AAPL, AMZN, GOOG, JPM, META)과 한국 5종목(삼성전자, SK하이닉스, 현대차, 한국전력, 현대모비스)의 2017

년 1월~2026년 9월 매 거래일에 대해 다음 날 로그수익률의 분포를 예측하였다(24,132건).

두 환경 모두 같은 절차를 쓴다. TSFM 4종(Chronos-T5, Chronos-2, TimesFM-2.5, Moirai-2.0)을 과거 길이 2가지(21일, 252일) × 입력 형태 2가지(수익률, 가격) = 4개 조건에서 평가하고, RW와 GARCH(1,1)-t를 기준 모형으로 둔다. RQ3은 두 환경 모두에 같은 사후보정을 적용해 답한다.

실험 설정, 가설, 판정 기준, 분석 코드는 실행 전에 git 커밋으로 동결하였다(사전등록). 동결 후의 변경과 실행 중 발견한 사항은 모두 기록하여 밝힌다.

1.4 주요 결과와 기여

본 연구의 주요 결과는 다음과 같다.

1. 오차의 출처는 금융 특성보다 모델과 입력 설정이다. 특성이 전혀 없는 데이터에서 이미 TSFM의 80% 구간 커버리지는 14%에서 88%까지 퍼져 있었고, 특성을 실제 종목 중 가장 강한 수준(L5)으로 설정해도 대부분 3%p 이내로만 움직였다. 변동성 군집만 일부 조건에서 커버리지를 낮췄고, 두꺼운 꼬리와 잦은 국면 전환 특성은 오히려 커버리지를 높였으며, 이는 80% 구간이 갖는 수학적 성질로 설명된다.
2. 합성 데이터 실험의 진단은 실제 주가에서 재현된다. 실제 10종목의 커버리지는 특성 없는 합성 데이터의 커버리지와 평균 1.0%p(구간이 붕괴한 Chronos-T5 수익률 2개 조건 제외, 19개 전체는 1.2%p, 최대 3.6%p) 차이였다. 실제 데이터에 적용하기 전에 합성 데이터로 잘못된 설정을 미리 찾아낼 수 있다는 뜻이다.
3. 사후보정은 모든 경우에 평균 커버리지를 80%로 복원한다. 합성 340개, 실제 19개 모델·조건에서 예외가 없었으며, 그에 상응하여 구간의 폭은 이상적인 구간보다 6~48% 넓어졌다. 탐색 분석에서는 위반율이 40% 안팎이던 VaR 10% 한도가 보정 후 10% 수준으로 돌아왔다.
4. 분포 정확도는 단순 기준 모형 수준이다. 실제 주식에서 분위수 손실은 16개 조건 중 13개에서 RW보다 컸고, 가장 나은 조건(Chronos-T5를 제외한 세 모델의 1년·수익률)에서 RW와 같은 수준이었다. 점 예측 연구에서 보고된 한계가 분포 예측에서도 나타난 것으로, TSFM 예측구간의 쓸모가 수익률 예측보다 보정을 거친 위험 측정에 있음을 뜻한다.

이를 바탕으로 한 본 연구의 기여는 다음과 같다.

- 방법론: 실제 종목에서 측정한 특성 강도로 합성 데이터의 강도 단계를 설정하고, 공통 난수로 특성 하나씩만 바꾸는 통제 실험을 TSFM 예측구간 진단에 적용하였다. 이 설계로 합성 데이터 실험의 결과가 실제 주가에서 평균 1.0%p 차이로 재현됨을 확인하여, 실제 데이터에 적용하기 전에 입력 설정을 점검하는 절차로 쓸 수 있음을 보였다(5.4 절).
- 평가 관점: 꼬리가 두꺼운 분포에서 분산 기반 80% 구간의 커버리지가 오히려 올라가고, 그 방향이 구간 수준에 따라 바뀜(99% 구간에서는 하락)을 이론 계산으로 보였다. 단일 구간의 커버리지만으로 꼬리 위험을 판단하면 잘못된 결론에 이를 수 있다(4.3.2 절).
- 실증: 최신 TSFM 4 종을 두 시장, 약 10 년, 4 개 사용 조건에서 사전등록 절차로 평가하고, 결과를 선택하지 않고 전체 표로 보고하였다.
- 실무: TSFM 예측구간을 위험 관리에 쓸 때 입력 설정 점검과 사후보정이 필요함을 보이고, 이것이 변동성 목표·VaR 같은 실제 의사결정에 어떤 차이를 만드는지 탐색하였다(5.5 절).

1.5 논문 구성

제2장은 관련 연구를 정리한다. 제3장은 연구 설계를, 제4~6장은 RQ1~RQ3의 결과를 차례로 다룬다. 제7장은 결론과 한계, 향후 연구를 제시한다.

제 2 장 관련 연구

2.1 금융 수익률의 특성

일별 주가 수익률에는 여러 시장과 기간에서 반복적으로 관찰되는 성질(stylized facts)이 있다(Cont, 2001). 본 연구가 다루는 세 가지는 다음과 같다.

- 변동성 군집: 큰 변동 뒤에 큰 변동이, 작은 변동 뒤에 작은 변동이 이어지는 성질이다. ARCH(Engle, 1982)와 GARCH(Bollerslev, 1986) 모형이 이를 표현하며, GARCH(1,1)에서 $\alpha+\beta$ 가 1 에 가까울수록 군집이 오래 지속된다.
- 두꺼운 꼬리: 정규분포보다 극단적인 날이 훨씬 자주 나타나는 성질이다. 흔히 자유도 ν 의 Student-t 분포로 표현하며, ν 가 작을수록 꼬리가 두껍다.
- 국면 전환: 시장이 평온기와 격변기를 오가며, 국면마다 변동 수준이 다른 성질이다. Hamilton(1989)의 마르코프 전환 모형이 대표적이다.

이 성질들은 실제 데이터에서 함께 나타나므로 실제 주가만으로는 개별 특성의 영향을 분리하기 어렵다. 이에 본 연구는 합성 데이터로 특성을 하나씩 통제하여 실험을 수행한다.

2.2 시계열 파운데이션 모델

TSFM은 다양한 분야의 대규모 시계열로 사전학습하여, 새 데이터에 추가 학습 없이(제로샷) 예측을 내는 모델이다. 본 연구가 평가하는 네 모델은 다음과 같다.

- Chronos(Ansari 외, 2024): 과거 구간의 평균 절댓값으로 값을 나눈 뒤(mean scaling) [-15, +15] 범위를 같은 폭의 구간으로 나누어 토큰으로 바꾸고(어휘 4,096 개), 언어 모델(T5) 구조로 다음 토큰을 예측한다. 예측을 여러 번 표본 추출해 분포를 얻는다. 저자들은 이처럼 평균 절댓값으로 나눈 뒤 고정 범위를 구간화하므로 입력 계열의 값 분포에 따라 표현 범위와 정밀도가 달라질 수 있다는 한계를 밝혔다.
- Chronos-2(Ansari 외, 2025): 단변량뿐 아니라 다변량·공변량 예측을 제로샷으로 지원하도록 확장한 모델로, 관련 계열 사이에 정보를 공유하는 그룹 어텐션을 사용하고 합성 데이터로 학습하였다. 0.01, 0.05, 0.1, …, 0.9, 0.95, 0.99 의 21 개 분위수를 직접 출력하며, 본 연구는 네 모델이 공통으로 출력하는 0.1~0.9 의 9 개 분위수만 사용하였다.
- TimesFM(Das 외, 2024): 시계열을 일정 길이의 조각(패치)으로 나누어 디코더 구조(decoder-only)로 예측하는 모델이다. 본 연구는 개선판인 TimesFM-2.5(200M)를 사용하며, 이 모델은 평균과 0.1~0.9 분위수를 출력한다.
- Moirai(Woo 외, 2024)와 Moirai-2.0(Liu 외, 2025): Moirai 1.0 은 여러 패치 크기와 혼합분포 출력을 사용하는 마스크 인코더 구조였으나, Moirai-2.0 은 이를 단일 패치·디코더 구조·분위수(pinball) 손실로 단순화하고 0.1~0.9 의 9 개 분위수를 출력한다. 3,600 만 개 계열로 학습되었으며, 저자들은 이전 최고 버전(Moirai 1.0-Large)보다 약 2 배 빠르고 30 배 작다고 보고하였다. 본 연구에서 사용한 small 모델의 파라미터 수는 1,140 만 개이다.

이 모델들의 성능은 주로 여러 분야를 모은 벤치마크(GIFT-Eval 등)의 정확도와 분위수 손실로 보고되었고, 금융 수익률에서 예측구간이 명목 커버리지를 충족하는지는 개발 단계에서 별도로 검증되지 않았다.

2.3 금융에서의 TSFM 평가

Rahimikia 외(2025)는 94개 국가·지역의 일별 초과수익률(1990~2023)을 대상으로 TSFM을 제로샷, 미세조정, 처음부터 사전학습의 세 방식으로 평가하였다. 다음 날 초과수익률을 예측하는 과제에서 제로샷으로 사용한 Chronos(tiny~large 5종)와 TimesFM(4종)은 표본 외 R^2 가 음수였고(512일 과거 창에서 Chronos large −1.37%, TimesFM 500M −2.80%), CatBoost 같은 앙상블 모형보다 성능이 낮았다. 금융 데이터로 처음부터 사전학습하면 정확도와 포트폴리오 성과가 크게 향상되었으나, 설명력(R^2)은 여전히 기준 모형에 미치지 못하였다. 평가 지표는 표본 외 R^2 , 방향 정확도, 포트폴리오 성과였으며, 예측구간의 커버리지는 평가하지 않았다.

Noguer i Alonso와 Franklin(2026)은 미국 대형주 5종목(GOOG, AAPL, AMZN, JPM, META)의 일별 수익률에서 Chronos(v1), Chronos-2, TimesFM-2.5, Moirai-2.0 등 사전학습 모델을 처음부터 학습한 신경망(N-BEATS, PatchTST, iTransformer 등)과 비교하였다(2014-09~2026-02, 과거 512일, 20영업일 앞 예측). 사전학습 모델이 10개 과제 중 8개에서 우위를 보였으나 랜덤워크(수익률 0 예측) 대비 이득은 작았고, 단측 Diebold-Mariano 검정에서 랜덤워크보다 유의하게 나은 경우는 Chronos(v1)의 AMZN과 Moirai-2.0의 GOOG 두 건뿐이었다. 평가 지표는 예측 중앙값의 MAE였으며, 저자들은 CRPS·보정 곡선·분위수 커버리지가 "현재의 MAE 전용 벤치마크에 포함되지 않는다"고 밝혔다(p. 13). 이 연구는 확률 출력을 중앙값으로 축약하여 점 예측으로만 평가하였다. 본 연구의 미국 종목과 TSFM 구성은 이 연구와 동일하게 맞추었다.

두 연구는 결론의 강도가 다르지만, 제로샷 TSFM이 금융 수익률의 점 예측에서 단순 기준을 크게 넘지 못한다는 점에서는 일치한다. 그러나 두 연구 모두 예측구간의 신뢰성은 다루지 않았다. 방향을 맞히지 못하는 모델이라도 변동의 크기를 적절히 추정한다면 위험 관리에 활용할 수 있으므로, 예측구간의 신뢰성은 점 예측 평가와 별개로 검증할 필요가 있다.

2.4 합성 데이터를 이용한 진단

Sun 외(2026)는 FinStressTS 벤치마크를 통해 금융 시계열의 대표적 생성 메커니즘(변동성 군집, 다중 시간 척도 지속성, 두꺼운 꼬리 충격, 국면 전환, 자기 흥분 점프, 0 과다)을 조절한 30개 진단 환경에서 15개 예측 모델(HAR, VAR, PatchTST, iTransformer, DeepAR 등)을 평가하였다. 생성 메커니즘을 알고 있으므로 실패의 구조적 원인을 특정할 수 있다는 점을 강조하였으며, 점 예측(NMAE)과 확률 예측(CRPS)을 평가하였다. 그 결과 메커니즘에 따라 모델 간 우열이 달라지고, 변동성 · 꼬리 · 점프 환경에서는 자기회귀 · 선형 모형이 트랜스포머보다 경쟁력이 있다고 보고하였다. 평가 대상 15개 모델은 모두 해당 합성 데이터로 학습하는 예측 모델이며, 학습 데이터 양을 20~100%로 바꾼 학습 곡선도 함께 보고되었다. 사전학습 TSFM은 관련 연구에서 언급되었을 뿐 평가 대상에 포함되지 않았고, 확률 예측은 CRPS로만 평가되어 예측구간의 커버리지는 별도로 분석되지 않았다.

Wang 외(2025)는 모바일 게임 이용자 참여 예측에서 TSFM이 도메인 맞춤 모델보다 성능이 낮은 원인으로 사전학습 시 접하지 못한 주파수 성분(스펙트럼 이동)을 지목하고, 이를 합성 실험으로 확인하였다. 합성 실험은 사전학습 모델(MOMENT-small)의 인코더를 고정하고 회귀 헤드만 학습하는 방식으로 수행되었다. 금융 데이터를 다루지는 않았으나, TSFM의 실패 원인을 합성 데이터 통제 실험으로 분리한다는 접근을 본 연구와 공유한다.

본 연구는 FinStressTS의 진단 아이디어를 사전학습 TSFM의 예측구간에 적용하되, 두 가지를 보완한다. 첫째, 특성 강도의 단계를 실제 평가 종목에서 측정한 값으로 설정하여 합성 데이터 실험과 실제 주가 실증을 직접 연결한다. 둘째, 공통 난수와 고정된 평균 변동 크기를 사용하여 특성 하나의 효과만 분리한다.

2.5 예측구간의 평가와 사후보정

확률 예측은 보정(calibration, 명목 확률대로 맞는가)과 날카로움(sharpness, 얼마나 좁은가)을 함께 보아야 하며, "보정을 지키는 범위에서 날카로움을 최대화"하는 것이 목표이다(Gneiting, Balabdaoui, Raftery, 2007, p. 8). 분위수 손실과 CRPS는 이런 평가에 쓰이는 적정 점수 규칙이다(Gneiting, Raftery, 2007). 본 연구는 보정을 80% 구간의 커버리지로, 분포 전체의 정확도를 분위수(pinball) 손실로 본다. 금융 위험 관리에서는 VaR 위반율을 Kupiec(1995)의 비조건부 검정과 Christoffersen(1998)의 독립성 검정으로 점검하는 것이 표준이다.

콘포멀 예측은 모델 구조와 무관하게 과거 오차의 분포로 구간을 조정해 커버리지를 보장하는 방법이다. 콘포멀 분위수 회귀(CQR, Romano 외, 2019)는 모델이 낸 분위수 구간을 과거 이탈 점수만큼 넓히거나 좁힌다. 다만 기본 콘포멀 예측은 데이터의 교환 가능성을 가정하므로, 분포가 시간에 따라 바뀌는 금융 시계열에는 그대로 맞지 않는다. 적응형 콘포멀 추론(ACI, Gibbs, Candès, 2021)은 실제값이 구간을 벗어났는지에 따라 목표 수준 α를 온라인으로 갱신하여, 분포가 바뀌는 경우에도 장기 평균 커버리지를 목표에 맞춘다. 본 연구는 두 방법을 결합한 ACI-CQR을 사용하며(3.5절), 이 방법은 재학습 없이 출력만 조정하므로 사전학습 모델에 그대로 적용할 수 있다.

2.6 본 연구의 위치

표 2-1은 관련 연구와 본 연구의 범위를 비교한다.

표 2-1. 관련 연구 비교

연구	TSFM 제로샷	금융 수익률	합성 진단	구간 커버리지	사후보정
Rahimikia 외(2025)	○	○ (94개 국가 · 지역)	×	×	×
Noguer i Alonso, Franklin(2026)	○	○ (미국 5종목)	×	×	×
Sun 외(2026) FinStressTS	×	합성	○ (6개 메커니즘)	× (CRPS)	×
Wang 외(2025)	△ (고정 백본+학습 헤드)	×	○ (주파수)	×	×
Gibbs, Candès(2021); Romano 외(2019)	×	해당 없음 (방법론)	×	○	○
본 연구	○ (4종 × 4조건)	○ (미국 · 한국 10종목)	○ (4축, 실측 모수)	○	○

정리하면, 금융 TSFM 연구는 점 예측 정확도에, 합성 진단 연구는 학습형 모델에, 사후보정 연구는 방법 자체에 초점을 두었다. 본 연구는 이 세 흐름이 만나는 지점, 즉 사전학습 TSFM의 금융 예측구간이 명목 수준을 벗어나는 원인과 그 교정 방법을 다룬다.

제 3 장 연구 설계

본 장에서는 실험의 설계를 설명한다. 3.1절에서 예측 문제를 정의하고, 3.2절에서 합성 데이터, 3.3절에서 실제 주식 데이터를 다룬다. 3.4절은 비교 모델, 3.5절은 사후보정, 3.6절은 평가 지표와 가설 검정, 3.7절은 사전등록과 검산 절차를 설명한다. 합성 데이터 실험과 실제 주가 실증은 같은 예측 절차와 같은 지표를 쓰며, 다른 것은 데이터뿐이다.

3.1 예측 문제

본 연구가 평가하는 대상은 TSFM이 내놓는 내일 로그수익률의 80% 예측구간이다. 매 거래일 t에 과거 L일의 자료만 보고 다음 날 수익률 $r_{t+1} = \ln(P_{t+1}/P_t)$의 분포를 예측하며, 일별 이동 창(rolling window) 방식으로 동일한 예측을 반복한다. 모델은 재학습하지 않는다(제로샷).

표 3-1. 예측 문제 설정

항목	설정	근거
예측 대상	다음 날 로그수익률	일 단위 위험 관리(VaR 등)가 실무 표준이며, 기준 연구인 Re(Visiting)도 다음 날을 예측함
출력	0.1, 0.2, …, 0.9 분위수 9개	비교 모델 네 개가 공통으로 낼 수 있는 분위수 범위
평가 구간	80% 구간 = $[q_{0.1}, q_{0.9}]$	일부 모델(TimesFM-2.5, Moirai-2.0)이 0.1~0.9 분위수만 출력하므로 네 모델이 공유하는 가장 넓은 대칭 구간
과거 길이 L	21일(약 한 달), 252일(약 1년)	단기 정보만 쓰는 경우와 1년치 맥락을 쓰는 경우 비교
입력 형태	① 로그수익률 ② 가격 그대로	TSFM은 입력을 내부에서 정규화하지만 입력 형태에 따라 출력이 달라질 수 있음. 가격 입력의 출력 분위수 q는 $\ln(q/P_t)$로 바꿔 채점
에피소드	80일 = 준비 20일 + 채점 60일	준비 20일은 사후보정 기록을 시작하는 데만 쓰고, 모든 지표는 채점 60일로 계산

과거 길이 2가지와 입력 형태 2가지를 교차하여 TSFM마다 4개 조건(한 달 · 수익률, 한 달 · 가격, 1년 · 수익률, 1년 · 가격)을 구성하고, 모든 실험 결과는 조건별로 구분하여 제시한다.

에피소드 길이 80일은 다음 계산에서 정하였다. 80% 구간은 평균 다섯 날에 한 번 구간을 벗어나므로, 채점 60일 동안 약 12회의 이탈이 누적된다. 사후 보정은 과거 이탈 기록을 바탕으로 구간을 조정하는 방식이므로, 이 정도의 이탈 기록이 있어야 보정 효과를 검증할 수 있다.

3.2 실측 기반 합성 데이터

3.2.1 설계 원칙

합성 데이터 실험의 목적은 금융 데이터의 특성 하나만 강하게 설정했을 때 예측구간이 어떻게 변하는지를 분리해서 보는 것이다. 이를 위해 세 가지 원칙을 지켰다.

첫째, 같은 난수를 공유한다(공통 난수, common random numbers). 계열 번호 s마다 난수(정규난수 z, 균등난수 u · v, 초기 상태 s_0)를 한 번만 뽑고, 모든 시나리오가 이를 함께 쓴다. 따라서 같은 계열 번호의 L1과 L5 차이는 우연이 아니라 특성 설정의 차이에서만 생긴다. 네 축의 L1 모수($\alpha+\beta = 0$, $\nu = \infty$, 전환 없음, 변동비 1)로 데이터를 만들면 모두 같은 L1 계열이 되는지를 생성 코드가 실행할 때마다 점검한다.

둘째, 변동의 크기는 고정한다. 모든 시나리오의 무조건부 평균은 0, 하루 변동(무조건부 표준편차)은 2.11%로 같다. 바뀌는 것은 변동의 형태뿐이다.

셋째, 강도 단계는 실제 주식에서 정한다. 합성 단계를 연구자가 임의로 정하면 실제보다 지나치게 약하거나 강한 조건을 시험하게 된다. 본 연구는 실제 10종목(3.3절)에서 각 특성의 강도를 측정하고, 그 측정값으로 단계를 정하였다.

3.2.2 금융 데이터의 세 가지 특성

주식 수익률은 정규분포와 다른 세 가지 성질을 보인다고 널리 알려져 있다. 그림 3-1은 실제 주가에서 이 성질이 어떻게 나타나는지 보여 준다.

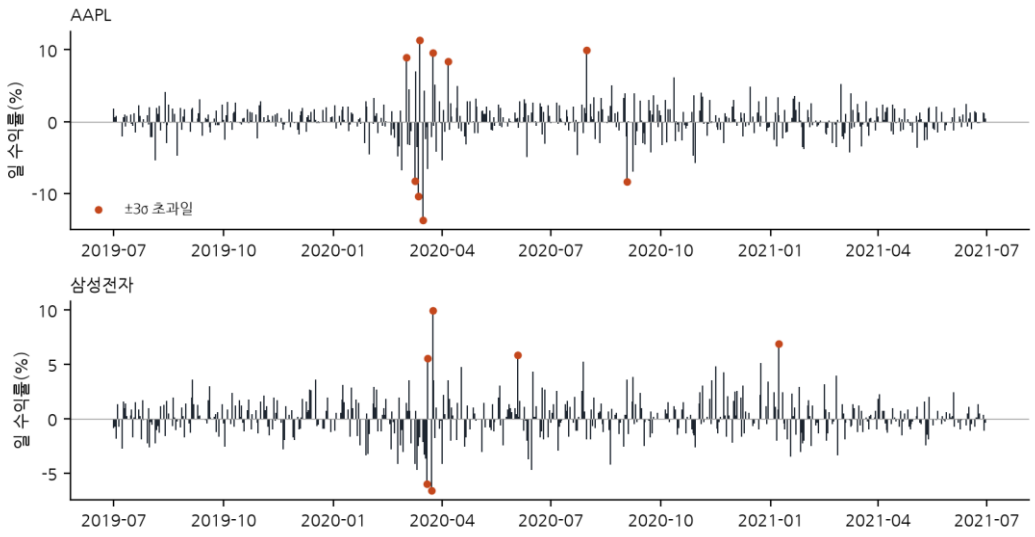


그림 3-1. 실제 주식의 하루 수익률(2019-07 ~ 2021-06)

2020년 3월 전후로 큰 움직임이 몰려서 나타나고(변동성 군집), 평소 변동의 3배를 넘는 날(빨간 점)이 정규분포가 예상하는 것보다 훨씬 자주 나타난다(두꺼운 꼬리). 저변동기와 고변동기가 번갈아 나타나는 모습은 국면 전환으로도 볼 수 있다.

① 변동성 군집: 한 번 크게 움직이면 그 뒤 며칠에서 몇 주 동안 계속 크게 움직이는 성질이다. GARCH(1,1) 모형으로 표현하며, 지속성 $\alpha+\beta$가 0이면 어제의 변동이 오늘에 영향을 주지 않고, 1에 가까울수록 변동의 영향이 오래 지속된다.

② 두꺼운 꼬리: 평소에는 변동이 작다가 간헐적으로 극단적인 일별 변동이 발생하는 성질이다. 군집과 달리 극단적인 수익률이 특정 시기에 집중되지 않고 무작위로 발생한다. Student-t 분포로 표현하며, 자유도 ν가 작을수록 극단적인 날이 잦다. 표 3-2의 실제 10종목에서 평소 변동의 3배를 넘은 날의 비율은 1.3~1.8%로, 정규분포라면 기대되는 0.27%의 5~7배였다. 5배를 넘은 날은 정규분포에서는 사실상 일어나지 않지만(약 2,900일에 0.002일) 실제로는 종목마다 5~11일 있었다.

③ 국면 전환: 시장이 평온한 상태와 격변 상태를 오가는 성질이다. 2국면 마르코프 전환 모형으로 표현한다. 본 연구는 이 특성을 두 축으로 나눈다. 전환 빈도(국면 지속 기간)와 전환 크기(국면 간 변동성 비율)를 구분하지 않으면 어느 쪽이 영향을 주는지 식별할 수 없기 때문이다. 그 결과 합성 축은 군집 · 꼬리 · 전환 빈도 · 전환 크기의 4개로 구성된다.

3.2.3 실제 10 종목에서 특성 강도 측정

10종목(3.3절) 각각의 2015-01-02~2026-09-22 일별 로그수익률(×100)에 두 모형을 적합하였다.

- GARCH(1,1)-t, 상수 평균(arch 8.0.0): $\alpha+\beta$(군집), ν(꼬리)를 얻는다.
- 2 국면 마르코프 전환, 평균 · 분산 전환(statsmodels 0.15.0): 국면별 평균 지속일 $1/(1-p_{ii})$와 격변/평온 표준편차 비(변동비)를 얻는다. 무작위 시작값 30 개로 추정하여 로그우도가 가장 큰 해를 택하였다.

국면 전환 추정에서 한 가지 문제가 있었다. 한국 종목은 호가 단위 때문에 종가가 전날과 같은 날이 4~7% 있고, 이런 날들이 모여 "분산이 0인 국면"이라는 퇴화해(degenerate solution)를 만들 수 있다. 이런 해는 우도가 무한히 커지는 수학적 특이해로서 실제 시장의 성질이 아니다. 이를 막기 위해 국면 표준편차가 표본 표준편차의 25% 미만인 해는 버리도록 했으며, 최종 추정에서는 10종목 × 30개 시작값 모두 정상 해로 수렴하였다. 거래량이 0인 날(삼

성전자 2018년 액면분할 거래정지 3일)은 제외했고, 같은 규칙을 실제 주식 실험에도 적용하였다.

표 3-2. 실제 10종목의 특성 측정값

종목	α+β (군집)	ν (꼬리)	평온 지속(일)	격변 지속(일)	변동비	일변동(%)	±3σ 초과(%)
AAPL	0.976	4.32	19.4	7.1	2.55	1.81	1.49
AMZN	0.972	4.46	32.3	12.4	2.52	2.07	1.49
GOOG	**0.996**	3.90	18.9	7.5	2.50	1.82	1.46
JPM	0.952	4.70	39.5	6.4	3.08	1.70	1.36
META	0.991	**3.56**	24.3	5.9	3.11	2.41	1.32
삼성전자	0.993	6.51	166.6	16.8	**3.19**	2.11	1.67
SK하이닉스	0.987	**7.64**	**275.2**	36.9	**2.50**	2.85	1.70
현대차	0.987	4.58	49.2	9.4	2.73	2.29	1.84
한국전력	**0.946**	4.11	20.7	6.3	2.68	2.10	1.43
현대모비스	0.977	4.28	40.1	6.8	2.74	2.35	1.56

굵은 글씨는 단계값의 출처가 된 최솟값 · 최댓값이다.

3.2.4 단계 규칙과 확정 단계값

단계 규칙은 측정 전에 정하여 사전등록 프로토콜에 기록하였다. L1은 특성 없음으로 4축이 공유하는 하나의 시나리오이다. L3은 10종목 중 가장 약한 값, L4는 중앙값, L5는 가장 강한 값이다. L2는 L1과 L3의 중간으로, 꼬리 축은 초

과첨도 6/(ν−4)의 중간에 해당하는 ν를 쓴다. 전환 빈도 축의 L5만 예외로, 실측 최대 이탈확률의 2배로 정해 실측 범위를 넘는 스트레스를 주었다.

표 3-3. 합성 데이터 단계값

단계	① 군집 α+β (α:β = 1:9)	② 꼬리 ν	③ 전환 빈도 (평온/격변 일수) (변동비 2.70 고정)	④ 전환 크기: 변동비 (지속 35.6/7.6일 고정)
L1	0	∞ (정규)	전환 없음	1.00
L2	0.473	11.28	550.4 / 117.5	1.75
L3	0.946 (한국전력)	7.64 (SK하이닉스)	275.2 / 58.7 (SK하이닉스)	2.50 (SK하이닉스)
L4	0.982 (중앙값)	4.39 (중앙값)	35.6 / 7.6 (중앙값)	2.70 (중앙값)
L5	0.996 (GOOG)	3.56 (META)	9.5 / 2.0 (최대 이탈확률×2)	3.19 (삼성전자)

하루 변동은 10종목 중앙값 2.11%, 평온/격변 지속일 비는 중앙값 4.69로 고정하였다. ③과 ④의 L4는 같은 설정이다. ③의 L2·L3은 평온 지속이 계열 길이(532일)와 비슷하거나 길어서 한 계열 안에서 전환이 0~2번에 그친다. 따라서 이 두 단계는 "자주 바뀜"보다 "계열마다 변동 수준이 다름"에 가깝다. 이는 규칙을 그대로 적용한 결과이며, 결과 해석에서 고려한다.

3.2.5 생성식

모든 시나리오는 하루 변동 σ = 2.11%, 평균 0을 만족한다.

- 군집(CL): $r_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$, $\alpha = 0.1(\alpha+\beta)$, $\beta = 0.9(\alpha+\beta)$, $\omega = \sigma^2(1-\alpha-\beta)$.
- 꼬리(TL): $r_t = \sigma \sqrt{((\nu-2)/\nu)} \cdot \tau_t$, $\tau_t = z_t / \sqrt{(\chi^2_\nu(v_t)/\nu)}$. 같은 z_t를 쓰므로 ν만 다르고 난수는 같다.
- 국면(RF·RS): 상태 $S_t \in$ {평온, 격변}이 평균 지속일에 따른 확률로 바뀌고, $r_t = \sigma_{St} z_t$. 격변 σ = 변동비 × 평온 σ이며, 정상분포 기준 분산이 σ^2가 되도록 두 값을 정한다. 두 국면의 평균은 모두 0이다.

계열 하나는 532일(워밍업 200일 + 과거 252일 + 에피소드 80일)이며, 시나리오 17개(L1 + 4축 × L2~L5) × 계열 100개를 만든다. 그림 3-2는 같은 난수로 만든 한 계열을 L1과 각 축의 L5로 비교한 것이다.

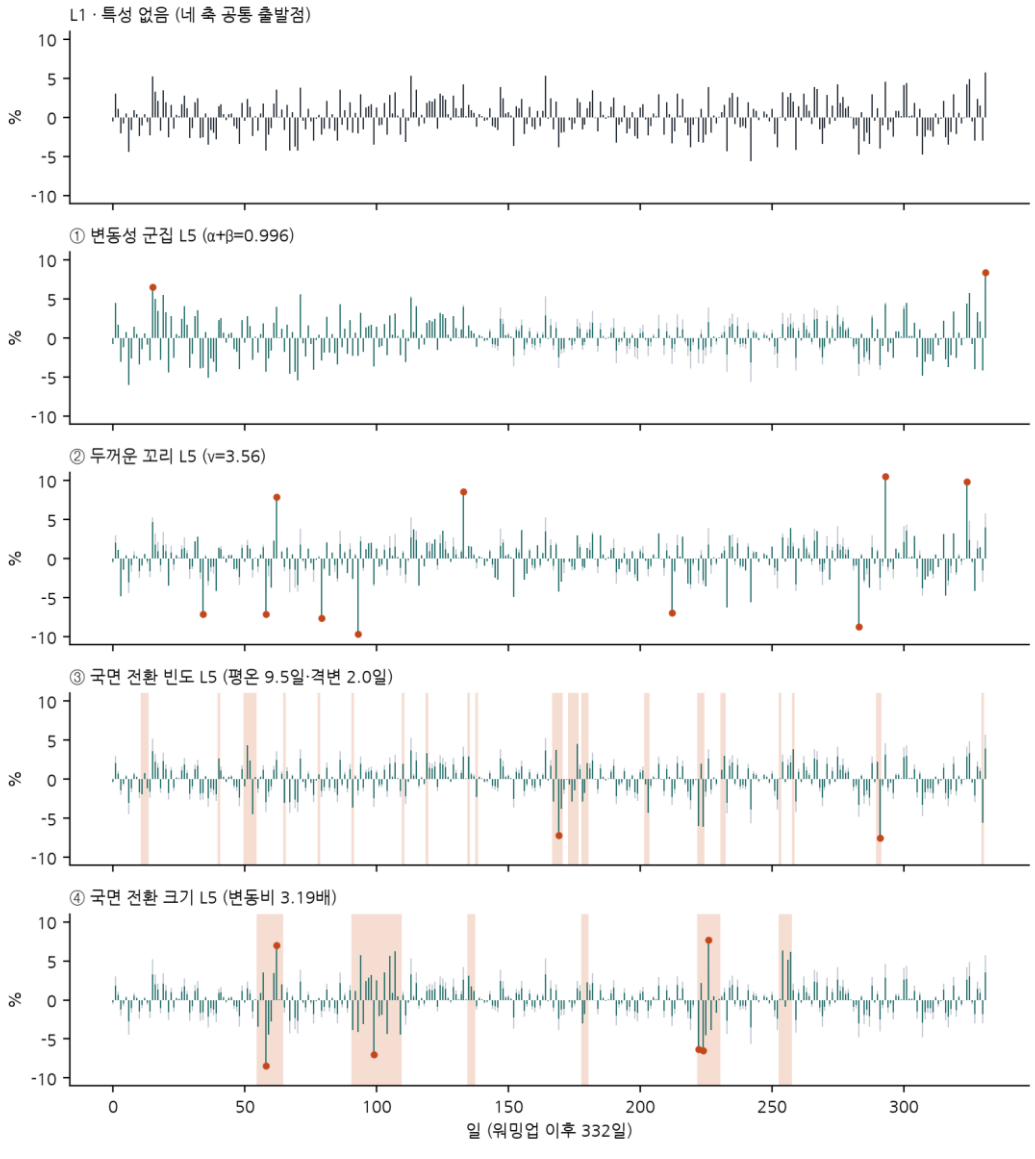


그림 3-2. 같은 난수로 만든 계열의 L1과 축별 L5

군집 L5는 고변동 구간과 저변동 구간이 몰려 나타나고, 꼬리 L5는 극단적인 수익률이 시기와 무관하게 흩어져 나타난다. 전환 빈도 L5는 짧은 격변(음영)이 자주 나타나고, 전환 크기 L5는 격변 구간 안의 변동이 커진다.

3.2.6 생성 검증

데이터가 의도대로 만들어졌는지 100개 계열 전체(워밍업 200일을 제외한 계열당 332일 × 100개 = 시나리오당 33,200일)로 확인하였다(표 3-4).

표 3-4. 합성 데이터 생성 검증

확인 항목	목표	생성 결과
하루 변동 (17개 시나리오)	2.11%	2.08~2.19%
L1의 ±3σ 초과일 비율	0.270% (정규분포)	0.271%
꼬리 L2~L5의 ±3σ 초과일 비율	0.676 / 0.879 / 1.264 / 1.379% (이론)	0.663 / 0.877 / 1.268 / 1.386%
군집 L2~L5의 제곱수익률 자기상관	단계가 오를수록 증가	0.045 / 0.122 / 0.151 / 0.165
국면 축의 격변 일수 비율	17.6%	16.6~17.7%
전환 크기 L2~L5의 변동비	1.75 / 2.50 / 2.70 / 3.19	1.76 / 2.52 / 2.72 / 3.21
전환 빈도 L4 · L5의 평균 지속일	35.6/7.6, 9.5/2.0일	31.4/7.4, 9.2/2.0일

군집 축의 자기상관은 이론값과의 일치 대신 증가 방향만 확인하였다. 계열 길이(332일)에서는 표본 자기상관이 이론값보다 작게 나오고, L5는 4차 적률이 존재하지 않아 이론값 자체가 정의되지 않기 때문이다. 전환 빈도의 실제 지속일이 목표보다 약간 짧은 것도 관측 기간이 끝나면서 마지막 구간이 잘리기 때문이다. 격변 일수 비율과 변동비가 목표와 일치하므로 전환 확률이 의도대로 들어갔다고 판단하였다.

추가로, 생성 과정을 알고 있으므로 각 날짜의 참 조건부 분포(군집: 그날의 σ_t를 아는 정규분포, 꼬리: 스케일된 t분포, 국면: 어제 국면을 알 때 오늘 국면의 혼합정규분포)의 분위수를 계산할 수 있다. 이를 오라클 모형이라 부르며, 데이터 생성과 채점 과정의 오류를 점검하는 기준선으로 활용한다(4.1절).

3.3 실제 주식 데이터

표 3-5. 실제 주식 데이터

항목	내용
미국 5종목	AAPL, AMZN, GOOG, JPM, META. 기준 연구(Noguer)와 같은 종목으로 재현 비교가 목적. 모두 2017년 초 미국 시가총액 상위 10위 안의 대형주
한국 5종목	삼성전자, SK하이닉스, 현대차, 한국전력, 현대모비스. 2017-01-02 KOSPI 보통주 시가총액 순위 위에서부터, 그 날 이전 거래 이력이 252일 이상인 종목 5개(우선주 제외, 4위 삼성전자우 제외). 순위 출처는 KRX 일별 시가총액 기록(FinanceData/marcap)
가격	2015-01-02~2026-09-22 일별 종가. 미국 yfinance(분할 반영 · 배당 미반영), 한국 FinanceDataReader(pykrx와 2,878일 전부 일치, 분할 의심 0건)
평가	2017-01-02부터 매 거래일 예측(종목당 2,381~2,443일, 총 24,132건). 종목별로 80일씩 연속 에피소드를 만들고, 끝에 80일이 안 되는 나머지는 주분석에서 제외(295개 에피소드, 채점 17,700건)
보조 분석	① 에피소드를 끊지 않는 연속 보정 ② 모델 공개 이후 기간만 따로 본 학습 데이터 누출 점검

한국 종목을 평가 시작 시점의 시가총액으로 고른 것은 사후 선택 편향을 막기 위해서이다. 2026년 기준으로 고르면 결과적으로 성장한 종목만 포함된다. 미국 종목은 선정 방식이 다르지만(기준 연구 재현), 모두 같은 시점의 대형주이므로 두 시장 모두 "2017년 시점 대형주"라는 공통 기준을 만족한다. 업종 구성은 미국이 기술 4 · 금융 1, 한국이 기술 2 · 자동차 2 · 전력 1로 다르다.

3.4 비교 모델

표 3-6. 비교 모델

구분	모델	출력 방식	조건
TSFM	Chronos-T5 base (amazon/chronos-t5-base)	표본 200개 → 분위수	4조건
TSFM	Chronos-2 (amazon/chronos-2)	분위수 직접 출력	4조건
TSFM	TimesFM-2.5 (google/timesfm-2.5-200m-pytorch)	평균 + 0.1~0.9 분위수	4조건
TSFM	Moirai-2.0-R-small (Salesforce/moirai-2.0-R-small)	분위수 직접 출력	4조건
기준 모형	과거 변동 기준선(랜덤워크 가정, RW)	과거 L일 수익률의 평균·표준편차를 갖는 정규분포	21·252일
기준 모형	GARCH(1,1)-t	매일 재추정한 1일 조건부 t분포	252일

TSFM 네 개는 기준 연구에서 평가한 모델과 맞추었다. Chronos-T5는 계산 시간 규칙에 따라 large 대신 base를 사용하였다(사전 측정에서 large 예상 19.4시간 > 기준 12시간). 과거 21일 조건에서는 TimesFM-2.5와 Moirai-2.0이 패치 길이보다 짧은 입력을 패딩(padding)하여 처리한다.

과거 변동 기준선(RW)은 "주가는 예측 가능한 방향 없이 움직인다"는 랜덤워크 가정에 따라, 최근 변동 크기만으로 다음 날 수익률의 정규분포를 산출한다. 학습이나 패턴 분석이 전혀 없는 가장 단순한 기준이다. GARCH(1,1)-t는 변동성 군집을 직접 모형화하는 전통적 계량 모형이다. 추정이 실패하거나 값이 비정상이면(유한값이 아님, 분산 ≤ 0, $\nu \leq 2$) 그날만 RW와 같은 분포로 대체하도록 사전에 정하였다.

모델이 낸 9개 분위수가 오름차순이 아니면(분위수 교차) 오름차순으로 다시 정렬한 뒤 채점하고, 교차 비율을 함께 보고한다.

3.5 사후보정

3.5.1 ACI-CQR

모델은 그대로 두고 출력 구간만 고치는 사후보정으로 적응형 콘포멀 추론(ACI)과 콘포멀 분위수 회귀(CQR)를 결합한 방식을 쓴다. 즉 전날까지의 구간 이탈 기록에 따라 당일 구간을 넓히거나 좁히는 방식이다.

1. 매일 이탈 점수 $s_t = \max(l_t - y_t,\ y_t - u_t) \,/\, (u_t - l_t)$를 기록한다. 구간 $[l_t, u_t]$ 안에 들어오면 음수, 밖으로 나가면 양수이며, 구간 폭으로 나누어 변동 크기와 무관하게 비교한다.
2. 준비 20일 동안은 점수만 기록한다.
3. 채점일에는 기록 n개 가운데 $k = \lceil (n+1)(1-\alpha_t) \rceil$번째로 작은 점수에 그날 구간 폭을 곱한 만큼 양쪽을 넓힌다(음수면 좁힌다). $k > n$이면 기록의 최댓값을 쓴다.
4. 실제값을 확인한 뒤 $\alpha_{t+1} = \mathrm{clip}(\alpha_t + \gamma(\alpha - \mathrm{err}_t),\ 0.02,\ 0.50)$로 갱신한다(단, err_t는 실제값이 구간을 벗어나면 1, 구간 안에 있으면 0). 이탈이 발생하면 α가 줄어 다음 구간이 넓어지고, 이탈 없이 포함이 이어지면 α가 늘어 구간이 좁아진다.

설정은 $\alpha = 0.20$, $\gamma = 0.05$로 고정하였다. 보정은 에피소드마다 새로 시작하며, 실제 주식에서는 종목별로 끊지 않는 연속 보정을 보조 분석으로 함께 보고한다.

3.5.2 대조군

보정의 효과가 단순히 "구간을 넓혀서" 생긴 것인지 확인하기 위해, 원래 구간을 중심 기준으로 일괄 확대한 대조군을 둔다. 확대 배율은 같은 묶음(합성은 모델 · 조건 · 시나리오, 실제는 모델 · 조건) 채점일의 평균 보정폭과 같아지도록 정한다. 이 배율은 결과를 본 뒤에 정한 값이므로 실제 운용에서는 알

수 없다. 즉 대조군은 미래 정보를 일부 사용한 비교 대상에 해당하며, 보정은 매일 그때까지의 실제값만으로 조정한다는 차이가 있다.

3.6 평가 지표와 가설 검정

3.6.1 지표

- 커버리지(주지표): 실제값이 80% 구간 안에 들어온 날의 비율. 목표는 80%이며, 80%보다 낮으면 구간이 좁아 위험을 과소평가한 것(과소), 높으면 불필요하게 넓은 것(과대)이다.
- 분위수 손실: 9 개 분위수의 pinball 손실 평균(CRPS 근사). 구간이 정확하면서 좁을수록 작다.
- 구간 폭: 보조 지표.

모든 지표는 채점 60일로만 계산한다.

3.6.2 연구 질문과 가설

표 3-7. 가설과 검정

연구 질문	가설	내용	비교	검정
RQ1	H1	군집이 강해질수록 커버리지 하락	같은 계열의 L5-L1, L5-L3	Wilcoxon 부호순위(양측)
RQ1	H2	꼬리가 두꺼울수록 하락	〃	〃
RQ1	H3a	전환이 잦을수록 하락	〃	〃
RQ1	H3b	전환 충격이 클수록 하락	〃	〃
RQ1	H4	고강도(L4·L5)에서 축마다 결손이 다르다	같은 계열 4축	Friedman → 축 쌍별 Wilcoxon
RQ2	H6	실제 주식에서 TSFM이 RW보다 분위수 손실이 작다	같은 날·종목, 같은 L	달력 월 블록 평균 차이의 t검정(양측)
RQ3	H5	보정 후 80% 복원	커버리지 90% 신뢰구간 ⊂ [0.77, 0.83]	클러스터 부트스트랩 2,000회

H1~H3b는 금융 시계열의 특성이 예측 모델에 불리하게 작용한다는 기존 연구(Sun 외, 2026 등)의 관점을 그대로 가설로 둔 것으로, 이 관점이 사전학습 TSFM의 예측구간에도 성립하는지를 검정한다.

검정 단위는 서로 독립인 묶음이다. 합성은 계열 100개(같은 계열 번호끼리 대응), 실제는 달력 월이다. 같은 날 10종목의 예측은 서로 연관되어 있고 연속된 날도 독립이 아니므로, 날짜를 하나하나 독립 관측으로 쓰지 않는다.

유의성은 Holm 보정 후 $p < 0.05$로 판단하며, Holm 묶음은 가설·비교마다 TSFM 4개 × 조건 4개 = 16개이다. 유의하더라도 효과가 실질 기준(커버리지 2%p, 분위수 손실 RW 대비 2%)보다 작으면 "통계적으로는 유의하나 작음"으로 구분한다. TSFM마다 4개 조건에서 각각 판정하여, 4조건 모두 성립하면 "조건

과 무관", 일부만 성립하면 "조건에 따라 다름", 없으면 "미지지"로 정리한다. 시나리오 · 모델 · 조건을 골라서 보고하지 않고 전체 표를 보고한다.

3.7 사전등록과 검산

본 연구의 실험은 실행 전에 연구 계획(가설 · 판정 기준) · 코드 · 단계값을 git 커밋으로 동결하고(동결 시점과 실행 환경은 부록 A), 동결 후의 변경은 이탈 기록과 새 커밋으로만 허용하는 사전등록 절차를 따랐다. 예비 실험에서 확인한 설계상의 한계를 보완하여 본 실험을 설계하고 실행 전에 동결하였으며, 동결 전에는 다음을 확인하였다.

- 누출 점검: 실제 · 합성 과제 각 600 건을 원자료에서 독립적으로 다시 계산하여, 모델에 주는 과거 자료가 예측 대상일 이전에서 끝나는지 확인
- 오라클 모형: 17 개 시나리오 모두 커버리지 79.3~80.2%
- 보정기: 별도로 작성한 참조 구현과 200 회 일치
- 예비 실행: 실제 GPU 환경에서 소규모 실행(스모크)으로 모든 모델의 호출 확인

실행 후에는 분석 코드와 독립적으로 작성한 코드로 원본 예측 파일에서 모든 지표와 검정을 다시 계산하여 일치함을 확인하였다(최대 차이 1.5×10^{-14}).

본 연구는 투명성을 위해 다음 사항을 밝힌다. 첫째, 동결 전 전체 규모 사전 시험에서 기준 모형(RW, GARCH-t)의 실제 주가 결과가 함께 산출되었으나, 이를 본 뒤 설정은 바꾸지 않았다. 둘째, 동결 후 검산에서 GARCH-t가 합성 데이터 136,000건 중 2건에서 비정상 값을 낸 것을 발견하였으며, 가설 검정에는 영향이 없고 민감도 분석을 6.5절에 보고한다.

실행 환경은 Python 3.11.17, PyTorch 2.5.1(CUDA 12.1), NVIDIA RTX 3080 10GB, chronos-forecasting 2.3.2, timesfm 3.0.2, uni2ts 2.0.0, arch 8.0.0 이다. 주요 패키지 버전은 부록 A.2에 싣는다.

제 4 장 금융 특성이 예측구간에 미치는 영향 (RQ1)

본 장에서는 합성 데이터 실험을 통해 TSFM 80% 예측구간의 오차가 금융 시계열의 특성(군집 · 꼬리 · 국면 전환)과 모델 · 입력 설정 중 어디에서 기인하는지 분석한다. 4.1절에서 실험 절차의 타당성을 확인하고, 4.2절에서 특성을 하나도 넣지 않은 기준 상태(L1)의 결과를, 4.3절에서 특성을 하나씩 강하게 설정했을 때의 변화(H1~H3b)를, 4.4절에서 특성끼리의 비교(H4)를 본다. 4.5절에서 RQ1에 답한다.

모든 수치는 시나리오마다 100계열 × 채점 60일 = 6,000건으로 계산한 보정 전 커버리지이다. 보정 후 결과는 제6장에서 다룬다.

4.1 실험 절차 점검

결과를 해석하기 전에 실험 절차가 타당한지 다음 세 가지를 확인하였다.

- 오라클 모형: 데이터를 만든 참 분포의 분위수를 그대로 낸 오라클 모형은 17 개 시나리오 모두에서 커버리지 79.3~80.2%였다(표 4-1 맨 아래 행). 따라서 채점 절차와 데이터 생성이 맞게 짝지어져 있고, 80%에서 벗어난 만큼은 모델의 책임이다.
- 분위수 교차: 9 개 분위수의 순서가 뒤바뀐 비율은 모든 모델 · 조건에서 0~0.11%였다(Chronos-2 1 년 · 가격 합성 0.11%가 최대). 정렬 후 채점 규칙이 결과에 주는 영향은 무시할 수준이다.
- 비정상 값: TSFM 은 유한하지 않은 값을 한 건도 내지 않았다. GARCH-t 는 136,000 건 중 2 건에서 추정 실패로 비정상적으로 큰 값(구간 끝이 수만~수천만 단위)을 냈다. 이는 커버리지에는 사실상 영향이 없고(79.31% → 79.31%) 평균 폭 · 손실 같은 서술용 평균값에만 영향을 준다. 가설 검정에는 GARCH-t 를 쓰지 않으므로 결론은 바뀌지 않는다. 상세는 6.5 절에 적는다.

4.2 기준 상태(L1)의 보정 전 커버리지

L1은 금융 특성이 하나도 없는 데이터이다. 매일 같은 크기(일 변동 2.11%)의 정규분포에서 독립적으로 추출하였으므로, 과거 변동성 기반 정규분포를 사용하는 단순 기준선(과거변동 RW)이 곧바로 정답에 가까워지는 가장 기본적인 환경이다. 그러나 표 4-1에서 보듯 TSFM은 이 기본적인 문제에서부터 이미 80%를 벗어났다.

표 4-1. 기준 상태(L1)와 전체 시나리오의 보정 전 커버리지

모델	조건	L1 커버리지(%) [95% 구간]	17개 시나리오 범위(%)	L1 평균 폭(%p)
Chronos-T5	한 달 · 수익률	14.7 [13.8, 15.6]	14.1~15.7	0.77
Chronos-T5	한 달 · 가격	75.3 [74.5, 76.1]	74.5~78.1	5.50
Chronos-T5	1년 · 수익률	14.0 [13.2, 14.8]	13.9~15.3	0.71
Chronos-T5	1년 · 가격	75.8 [74.8, 76.7]	74.4~77.5	5.09
Chronos-2	한 달 · 수익률	81.5 [80.8, 82.2]	80.5~82.0	6.40
Chronos-2	한 달 · 가격	79.8 [79.0, 80.7]	79.2~81.2	6.25
Chronos-2	1년 · 수익률	78.8 [77.8, 79.8]	77.1~80.8	5.36
Chronos-2	1년 · 가격	79.9 [78.6, 81.1]	77.3~83.0	5.70
TimesFM-2.5	한 달 · 수익률	77.5 [76.8, 78.3]	76.5~79.5	5.65
TimesFM-2.5	한 달 · 가격	77.2 [76.2, 78.1]	76.0~79.1	5.97
TimesFM-2.5	1년 · 수익률	78.8 [77.8, 79.8]	77.3~80.0	5.31
TimesFM-2.5	1년 · 가격	87.6 [86.5, 88.6]	86.8~88.4	7.00
Moirai-2	한 달 · 수익률	76.6 [75.9, 77.3]	75.7~78.8	5.51
Moirai-2	한 달 · 가격	77.5 [76.6, 78.3]	75.4~80.4	6.18
Moirai-2	1년 · 수익률	81.0 [80.1, 81.8]	79.7~82.0	5.59
Moirai-2	1년 · 가격	79.7 [78.5, 80.8]	77.8~81.1	5.74
과거변동(RW)	한 달 · 수익률	77.6 [76.8, 78.4]	75.9~82.0	5.38
과거변동(RW)	1년 · 수익률	79.4 [78.5, 80.5]	79.4~86.4	5.40
GARCH-t	1년 · 수익률	78.7 [77.7, 79.8]	78.4~80.1	5.34
오라클 모형	–	79.8 [78.7, 80.8]	79.3~80.2	5.40

주: 평균 폭은 80% 구간의 폭(로그수익률, %p). 오라클 모형의 폭 5.40%p가 이 데이터에서 "올바른

폭"이다.

표 4-1에서 확인되는 주요 특징은 다음과 같다.

① 같은 모델이라도 입력 형태에 따라 결과가 크게 다르다. Chronos-T5는 가격을 넣으면 75~76%로 약간 좁은 정도지만, 수익률을 넣으면 14~15%로 구간이 거의 붕괴한다. 이때 평균 폭은 0.7~0.8%p로, 필요한 폭(5.40%p)의 7분의 1에 불과하다. 실무적으로 말하면 "내일 수익률이 이 범위에 80% 확률로 들어간다"는 구간이 실제로는 15% 확률로만 맞는다는 뜻이다. 이 붕괴는 토큰화의 표현 범위로는 설명되지 않는다. Chronos는 입력을 평균 절댓값으로 나눈 뒤 ±15배 범위를 구간화하는데(2.2절), L1 수익률의 평균 절댓값은 약 1.7%이므로 표현 범위는 약 ±25%로 실제 수익률을 충분히 담는다. 값이 범위 밖으로 잘려서 구간이 좁아진 것이 아니라, 모델이 수익률 계열에 대해 지나치게 좁은 분포를 내도록 작동한 것이다. 내부 원인을 규명하는 것은 본 연구 범위 밖이며, 같은 계열의 Chronos-2에서는 이런 현상이 없다.

② 과거 길이에 따라서도 달라진다. TimesFM-2.5는 1년 · 가격에서만 87.6%로 구간이 지나치게 넓고(폭 7.00%p, 필요 폭의 1.3배), 나머지 세 조건에서는 77~79%로 약간 좁다. Moirai-2는 한 달 조건(77% 안팎)에서 좁고 1년 조건(80~81%)에서는 목표에 가깝다.

③ 목표에 가장 가까운 것은 Chronos-2이다. 네 조건이 모두 78.8~81.5%로, 실질 기준(±2%p) 안에 있다.

정리하면, 16개 TSFM 조건 중 L1에서 커버리지가 실질 기준(80% ± 2%p) 안에 든 것은 7개뿐이다. 금융 특성이 들어가기 전에 이미 모델과 입력 설정이 오차의 크기와 방향을 정하고 있다. 그림 4-1은 이 사실을 17개 시나리오 전체로 보여 준다. 그림에서 색상은 세로(열, 모델 · 조건) 방향으로 뚜렷하게 구분되는 반면 가로(행, 시나리오) 방향으로는 거의 변하지 않는다. 시나리오(금융 특성)에 따른 변화는 미미하고 모델과 입력 설정이 커버리지 수준을 결정한다. 표 4-1의 "17개 시나리오 범위" 열도 같은 결과를 보여 준다. Chronos-

T5 수익률(14~16%)과 TimesFM 1년 · 가격(87~88%)은 어떤 시나리오에서도 그 범위를 벗어나지 않는다.

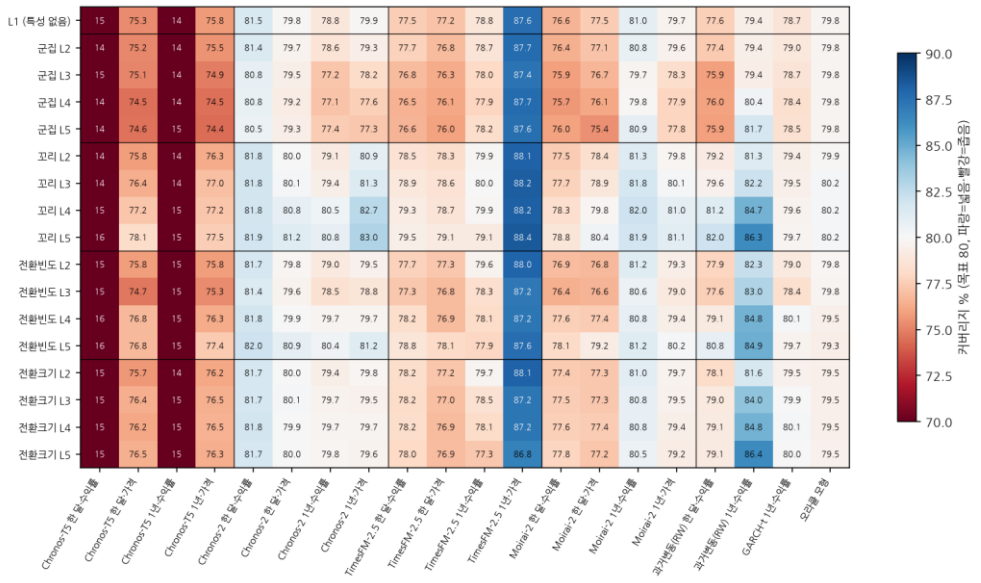


그림 4-1. 합성 데이터 시나리오별 보정 전 커버리지(%, 시나리오당 100 계열 × 채점 60 일)

4.3 특성 강도에 따른 커버리지 변화 (H1~H3b)

이제 같은 계열 번호(같은 난수)에서 특성 하나만 L1에서 L5로 강하게 설정했을 때 커버리지가 얼마나 변하는지 본다. 가설은 네 특성 모두 "강해질수록

커버리지가 떨어진다(구간이 상대적으로 좁아진다)"였다. 표 4-2는 L5-L1의 변화량, 그림 4-2는 L1부터 L5까지의 변화 경로이다.

표 4-2. 특성을 가장 강하게 설정했을 때(L5)의 커버리지 변화 (L5 − L1, %p)

모델	조건	H1 군집	H2 꼬리	H3a 전환빈도	H3b 전환크기
Chronos-T5	한 달 · 수익률	−0.6	+1.0	+1.0	+0.8
Chronos-T5	한 달 · 가격	−0.7	+2.8▲	+1.5△	+1.2
Chronos-T5	1년 · 수익률	+1.3	+0.7	+0.5	+1.3△
Chronos-T5	1년 · 가격	−1.4	+1.8△	+1.7△	+0.6
Chronos-2	한 달 · 수익률	−1.0	+0.4	+0.5	+0.2
Chronos-2	한 달 · 가격	−0.5	+1.4△	+1.0	+0.2
Chronos-2	1년 · 수익률	−1.4▽	+2.0△	+1.5	+0.9
Chronos-2	1년 · 가격	−2.5▼	+3.2▲	+1.3	−0.2
TimesFM-2.5	한 달 · 수익률	−0.9	+1.9△	+1.2△	+0.5
TimesFM-2.5	한 달 · 가격	−1.2▽	+1.9△	+0.9	−0.2
TimesFM-2.5	1년 · 수익률	−0.6	+0.2	−0.9	−1.5
TimesFM-2.5	1년 · 가격	0.0	+0.8	0.0	−0.8
Moirai-2	한 달 · 수익률	−0.6	+2.2▲	+1.5△	+1.2
Moirai-2	한 달 · 가격	−2.0▼	+2.9▲	+1.8△	−0.2
Moirai-2	1년 · 수익률	0.0	+0.9	+0.2	−0.4
Moirai-2	1년 · 가격	−1.8▽	+1.5	+0.5	−0.4
과거변동(RW)	한 달 · 수익률	−1.7	+4.5	+3.2	+1.5
과거변동(RW)	1년 · 수익률	+2.3	+6.8	+5.5	+7.0
GARCH-t	1년 · 수익률	−0.2	+1.0	+0.9	+1.3

표시: ▼ 가설 방향(하락)으로 유의하고 실질 기준(2%p) 이상, ▽ 가설 방향으로 유의하나 작음, ▲ 반대 방향(상승)으로 유의하고 2%p 이상, △ 반대 방향으로 유의하나 작음, 표시 없음 = 유의하지 않음. 유의성은 Wilcoxon 부호순위 검정, Holm 보정(16개 묶음) 후 $p < 0.05$. 기준 모형(RW, GARCH-t)은

서술용으로 검정하지 않았다. 비교 L5 − L3의 결과는 부록 B에 싣는다(16개 조건 모두 가설 방향으로 실질 유의한 것 없음).

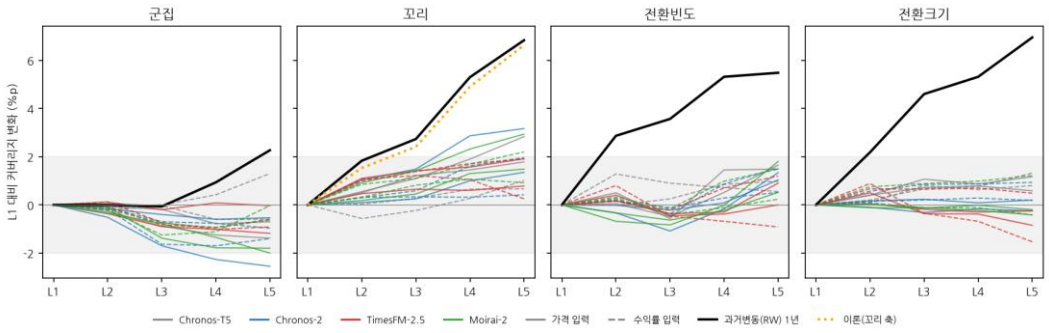


그림 4-2. 특성 강도에 따른 커버리지 변화(L1 대비, %p)

회색 띠는 실질 기준 ±2%p

4.3.1 변동성 군집(H1)의 영향

변동성 군집을 가장 강하게 설정하면($\alpha+\beta$ = 0.996, GOOG 수준) 대부분의 TSFM에서 커버리지가 조금 떨어졌다(그림 4-2 왼쪽, 선 대부분이 0 아래). 그러나 하락 폭이 실질 기준 2%p를 넘으면서 유의한 것은 Chronos-2 1년 · 가격(−2.5%p)과 Moirai-2 한 달 · 가격(−2.0%p) 두 조건뿐이다. 세 조건(Chronos-2 1년 · 수익률, TimesFM 한 달 · 가격, Moirai-2 1년 · 가격)은 유의하지만 2%p보다 작다. 나머지 11개 조건은 유의하지 않다. 사전에 정한 판정 규칙에 따라 H1은 Chronos-2와 Moirai-2에서 "조건에 따라 다름", Chronos-T5와 TimesFM에서 "미지지"이다.

변동성 군집이 강하게 나타나면 최근 변동을 빨리 따라가지 못하는 모델은 격변기에 구간이 좁아진다. 결과는 TSFM이 이 추종에 약간 늦다는 것을 보여주지만, 그 손실은 대부분 1~2%p 수준으로 L1에서 이미 있던 오차(표 4-1)보다 훨씬 작다.

4.3.2 두꺼운 꼬리(H2)의 영향

두꺼운 꼬리 특성을 강하게 설정하면(자유도 ν를 낮추면) 커버리지가 오히려 상승하였다. 16개 조건 중 9개에서 상승이 유의하였고(4개는 2%p 이상), 하락이 유의한 조건은 하나도 없다. 가설(H2)과 반대 방향이다.

이 결과는 80% 구간이 갖는 수학적 성질로 설명되며, 모델이 꼬리를 잘 다룬다는 뜻은 아니다. 분산을 동일하게 맞춘 정규분포와 두꺼운 꼬리를 갖는 t분포를 비교하면, t분포는 극단적인 관측치가 간헐적으로 발생하는 대신 중심부 밀도가 정규분포보다 높다. 따라서 분산이 동일한 정규분포 기반 80% 구간을 t분포 데이터에 적용하면 구간 내에 포함되는 비율이 80%를 상회하게 되며, 이론적 커버리지는 표 4-3과 같다.

표 4-3. 분산이 같은 정규분포 기반 구간을 t분포 데이터에 적용했을 때의 이론 커버리지 (%)

꼬리 단계	ν	80% 구간	95% 구간	99% 구간	99% 구간의 위반율
L1 (정규)	∞	80.0	95.0	99.0	1.0
L2	11.28	81.5	94.7	98.4	1.6
L3	7.64	82.4	94.7	98.2	1.8
L4	4.39	84.9	94.9	97.8	2.2
L5	3.56	86.6	95.2	97.8	2.2

과거 변동성 기반 정규분포를 사용하는 RW 1년이 정확히 이 경로를 따른다(그림 4-2 두 번째 칸, 검은 실선과 주황 점선이 거의 겹침. RW 1년 L5 86.3%, 이론 86.6%). TSFM의 상승 폭(0~3%p)은 RW보다 훨씬 작다. TSFM은 표본분산 기반 정규분포를 가정하는 방식보다는 꼬리 모양을 어느 정도 반영하지만, 완전히 반영하지는 못해 80% 구간이 약간 넓어진 것이다.

다만 이 결과는 80% 구간에 한정하여 해석해야 한다. 표 4-3에서 보듯 꼬리가 두꺼울 때의 효과는 구간 수준에 따라 방향이 바뀐다. 80% 구간에서는 커버리지가 올라가지만, 95% 근처에서 거의 변화가 없어지고, 99% 구간에서는 거꾸로 떨어진다. 99% 구간의 커버리지 하락은 1.2%p로 작아 보이지만, 위험 한

도로 보면 한도를 넘는 날의 비율이 1%에서 2.2%로 두 배 넘게 늘어난다는 뜻이다. 따라서 "80% 구간에서 꼬리는 불리하지 않다"는 본 연구의 결과를 극단 위험(99% VaR 등)에 그대로 적용해서는 안 된다. 본 연구는 네 모델이 공통으로 내는 0.1~0.9 분위수만 평가했기 때문에 극단 구간을 실험으로 확인하지 못하였다(제7장 한계). 극단 분위수(0.01, 0.99)를 함께 내는 Chronos-2(Ansari 외, 2025)로 이를 확인하는 것은 향후 과제로 남긴다.

4.3.3 국면 전환 빈도(H3a)와 크기(H3b)의 영향

전환 빈도를 높이면 5개 조건에서 커버리지가 유의하게 올라갔고(모두 2%p 미만), 내려간 조건은 없다. 전환 크기는 1개 조건에서 작게 올라간 것 말고는 유의한 변화가 없었다. 두 가설 모두 모든 모델에서 "미지지"이다. 같은 데이터에서 과거변동(RW) 1년의 커버리지가 5.5~7.0%p 움직인 것과 비교하면, TSFM은 국면 전환의 영향을 2%p 안으로 줄였다.

꼬리와 같은 원리가 작동한다. 평온기와 격변기가 섞인 데이터는 전체로 보면 꼬리가 두꺼운 분포가 된다(정규분포의 혼합). 예를 들어 전환 크기 L4(변동비 2.70, 평온 35.6일 · 격변 7.6일)를 단일 분포로 간주하고 정규분포 기반 80% 구간을 적용하면 이론 커버리지는 86.2%이다(같은 계산으로 95% 구간 94.5%, 99% 구간 97.1%로, 꼬리 축과 같은 방향 전환이 나타난다). RW 1년이 이 방향으로 크게 움직이는 것(+5.5~7.0%p)이 그 증거이다. TSFM은 최근 자료로 현재 국면의 변동성 수준을 일정 부분 포착하므로, 혼합 효과의 대부분을 피하고 0~2%p만 움직였다.

전환 빈도 L2 · L3은 제3장에서 밝혔듯 한 계열 안에서 전환이 0~2번에 그쳐 "자주 바뀜"보다 "계열마다 수준이 다름"에 가깝다. 이 단계들에서 변화가 거의 없는 것은 TSFM이 계열 수준 차이에는 잘 적응한다는 뜻으로 읽을 수 있다.

4.4 특성 간 결손 비교 (H4)

H4는 고강도(L4 · L5 평균)에서 네 특성의 결손(80% − 커버리지)이 서로 다른지를 같은 계열끼리 비교한다.

표 4-4. 고강도(L4 · L5)에서 특성별 결손 (80% − 커버리지, %p; 양수 = 구간이 좁음)

모델	조건	군집	꼬리	전환빈도	전환크기	범위(‰)	최대 결손	Holm p	판정
Chronos-T5	한 달 · 수익률	+65.9	+64.7	+64.4	+64.6	1.5	군집	3.3e-02	유의하나 작음
Chronos-T5	한 달 · 가격	+5.4	+2.3	+3.2	+3.7	3.1	군집	1.5e-04	축마다 다름
Chronos-T5	1년 · 수익률	+65.1	+65.3	+65.3	+64.9	0.4	전환빈도	7.5e-01	미지지
Chronos-T5	1년 · 가격	+5.5	+2.6	+3.1	+3.5	2.9	군집	1.2e-04	축마다 다름
Chronos-2	한 달 · 수익률	-0.6	-1.9	-1.9	-1.7	1.3	군집	4.2e-02	유의하나 작음
Chronos-2	한 달 · 가격	+0.7	-1.0	-0.4	0.0	1.7	군집	9.2e-03	유의하나 작음
Chronos-2	1년 · 수익률	+2.7	-0.6	0.0	+0.3	3.3	군집	1.2e-04	축마다 다름
Chronos-2	1년 · 가격	+2.5	-2.9	-0.4	+0.3	5.4	군집	2.6e-08	축마다 다름
TimesFM-2.5	한 달 · 수익률	+3.4	+0.6	+1.5	+1.9	2.8	군집	2.2e-04	축마다 다름
TimesFM-2.5	한 달 · 가격	+3.9	+1.1	+2.5	+3.1	2.8	군집	1.4e-07	축마다 다름
TimesFM-2.5	1년 · 수익률	+1.9	+0.5	+2.0	+2.3	1.8	전환크기	1.6e-01	미지지
TimesFM-2.5	1년 · 가격	-7.6	-8.3	-7.4	-7.0	1.3	전환크기	1.8e-01	미지지
Moirai-2	한 달 · 수익률	+4.2	+1.4	+2.1	+2.3	2.7	군집	4.7e-04	축마다 다름
Moirai-2	한 달 · 가격	+4.2	-0.1	+1.7	+2.7	4.3	군집	3.5e-11	축마다 다름
Moirai-2	1년 · 수익률	-0.4	-2.0	-1.0	-0.7	1.6	군집	6.4e-01	미지지
Moirai-2	1년 · 가격	+2.1	-1.0	+0.2	+0.7	3.2	군집	1.2e-03	축마다 다름
과거변동(RW)	한 달 · 수익률	+4.1	-1.6	+0.1	+0.9	5.7	군집	-	-
과거변동(RW)	1년 · 수익률	-1.0	-5.5	-4.8	-5.6	4.5	군집	-	-
GARCH-t	1년 · 수익률	+1.6	+0.3	+0.1	-0.1	1.6	군집	-	-

주: Friedman 검정(같은 계열 100개 대응), Holm 보정(16개 묶음). 범위 = 네 축 결손의 최댓값 − 최솟값. 판정은 Holm p < 0.05이고 범위가 실질 기준 2‰ 이상이면 "축마다 다름". 기준 모형(RW, GARCH-t)은 서술용으로 검정하지 않았다.

16개 조건 중 9개에서 "축마다 다름"이 지지되었고, 3개는 유의하나 차이가 2%p 미만, 4개는 미지지였다. 특히 "축마다 다름"인 9개 조건에서는 모두 결손이 가장 큰 축이 군집이었다. 축 쌍별 비교(Wilcoxon, Holm 보정)에서도 유의한 조건 수가 군집–전환빈도 12개, 군집–꼬리 12개, 군집–전환크기 8개로 군집 특성이 포함된 쌍에 집중되었고, 군집이 없는 쌍은 꼬리–전환빈도 3개, 꼬리–전환크기 3개, 전환빈도–전환크기 1개였다.

이 결과는 4.3절과 함께 읽어야 한다. 군집이 "가장 불리하다"는 것은 군집이 구간을 크게 좁혀서라기보다, 다른 세 특성은 80% 구간을 오히려 넓히는 쪽으로 작용하는데 군집만 좁히는 쪽으로 작용하기 때문이다. 예를 들어 Chronos-2 1년 · 가격의 결손은 군집 +2.5, 꼬리 −2.9, 전환빈도 −0.4, 전환크기 +0.3%p이다. 실무적 의미는 다음과 같다. TSFM의 80% 구간이 금융 특성 때문에 위험을 과소평가하게 된다면, 그 원인으로 가장 먼저 의심할 것은 변동성 군집(최근 변동을 따라가는 속도)이다.

4.5 소결

첫 번째 연구 질문(RQ1)에 대한 실험 결과를 요약하면 다음과 같다.

1. 오차의 대부분은 특성이 아니라 모델 · 입력 설정에서 온다. 특성이 전혀 없는 L1에서 이미 TSFM 커버리지는 14%부터 88%까지 퍼져 있고(표 4-1), 특성을 가장 강하게 설정해도 그 위치는 거의 움직이지 않는다(그림 4-1). 특히 입력 형태(수익률 vs 가격)와 과거 길이가 결과를 좌우한다.
2. 특성의 효과는 작고, 꼬리와 국면 전환은 통념과 달리 80% 구간에 불리하지 않았다. 군집만 예상한 방향(하락)이었고 실질적으로 큰 것은 2개 조건(-2.0~-2.5%p)이었다. 두꺼운 꼬리와 잦은 국면 전환 특성은 80% 구간의 커버리지를 오히려 높였으며, 이는 꼬리가 두꺼운 분포에서 분산 기반 80% 구간이 갖는 수학적 성질로 설명된다. 같은 성질 때문에 99% 구간에서는 방향이 반대가 되므로, 이 결과를 극단 위험에 그대로 적용할 수는 없다(표 4-3).
3. 특성끼리 비교하면 군집이 가장 불리하다(H4, 9개 조건). 다만 이는 다른 특성이 반대 방향으로 작용한 결과이기도 하다.

이 결과가 실제 주가에서도 성립하는지는 제5장에서 확인한다. 합성 데이터 실험에서 오차의 주된 원인이 모델 · 설정이었다면, 실제 주가에서도 커버리지는 L1과 비슷한 위치에 있어야 한다.

제 5 장 실제 주가에서의 예측구간 평가 (RQ2)

본 장에서는 실제 10종목(미국 5, 한국 5)에 대해 2017년 1월부터 2026년 9월까지 매 거래일 산출한 예측을 평가한다. 5.1절은 커버리지, 5.2절은 정확도(분위수 손실)를 과거변동(RW)과 비교한 H6, 5.3절은 모델 공개 이후 기간만 본 점검, 5.4절은 합성 데이터 실험 결과와의 대응을 다룬다. 5.5절은 사전등록 밖의 탐색 분석으로, 이 예측구간을 실제 투자 규칙에 썼을 때 어떤 차이가 생기는지를 본다. 5.6절에서 RQ2에 답한다.

5.1 보정 전 커버리지

표 5-1. 실제 10종목의 보정 전 커버리지 (채점 17,700건)

모델	조건	전체(%) [95% 구간]	미국(%)	한국(%)	종목별 범위(%)	평균 폭(%p)
Chronos-T5	한 달 · 수익률	16.9 [16.2, 17.5]	14.5	19.3	13.5~22.2	0.78
Chronos-T5	한 달 · 가격	76.5 [75.6, 77.4]	76.4	76.5	74.4~77.7	5.03
Chronos-T5	1년 · 수익률	17.6 [16.7, 18.6]	15.6	19.6	14.4~26.1	0.68
Chronos-T5	1년 · 가격	76.2 [75.1, 77.3]	76.6	75.8	74.0~78.0	4.33
Chronos-2	한 달 · 수익률	81.8 [81.0, 82.6]	82.0	81.6	81.0~82.2	5.75
Chronos-2	한 달 · 가격	81.1 [80.3, 81.9]	81.6	80.5	79.6~82.1	5.78
Chronos-2	1년 · 수익률	79.1 [77.9, 80.3]	79.1	79.1	78.0~80.1	4.65
Chronos-2	1년 · 가격	80.0 [78.8, 80.9]	79.8	80.1	78.3~80.9	5.02
TimesFM-2.5	한 달 · 수익률	78.2 [77.2, 79.1]	78.2	78.1	77.8~78.5	5.00
TimesFM-2.5	한 달 · 가격	77.8 [76.9, 78.6]	77.8	77.8	77.1~78.4	5.32
TimesFM-2.5	1년 · 수익률	77.2 [75.6, 78.7]	76.4	78.1	75.4~79.3	4.43
TimesFM-2.5	1년 · 가격	87.7 [86.7, 88.6]	87.1	88.4	86.0~89.2	6.27
Moirai-2	한 달 · 수익률	77.1 [76.1, 78.0]	77.3	76.8	76.3~77.9	4.85
Moirai-2	한 달 · 가격	78.7 [77.9, 79.4]	79.2	78.2	77.4~79.8	5.64
Moirai-2	1년 · 수익률	79.8 [78.4, 81.3]	80.1	79.6	78.6~81.1	4.69
Moirai-2	1년 · 가격	82.1 [81.3, 82.9]	83.0	81.2	80.3~83.8	5.20
과거변동(RW)	한 달 · 수익률	79.6 [78.6, 80.7]	79.9	79.3	78.7~80.3	4.93
과거변동(RW)	1년 · 수익률	83.0 [81.2, 84.7]	84.5	81.6	79.9~85.7	5.08
GARCH-t	1년 · 수익률	78.4 [77.2, 79.7]	78.6	78.3	77.3~79.2	4.54

주: 95% 구간은 달력 월 클러스터 부트스트랩 2,000회. 종목별 범위는 10종목 각각의 커버리지 최솟값~최댓값.

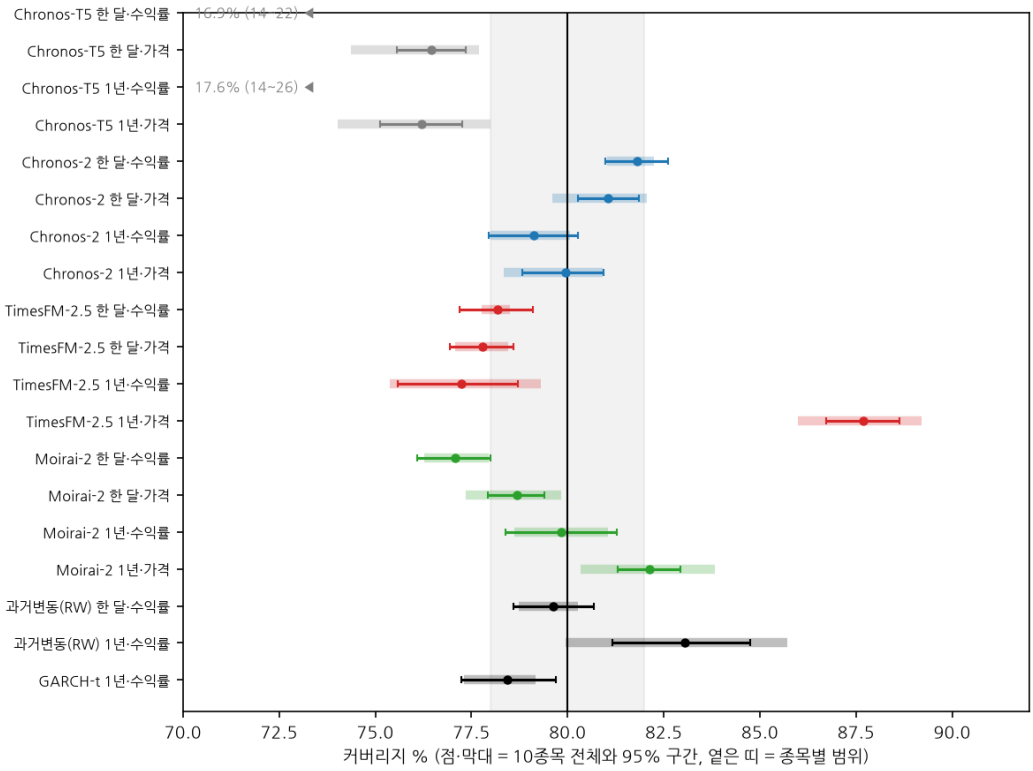


그림 5-1. 실제 10종목의 보정 전 커버리지(2017~2026, 17,700건)

점과 막대는 전체와 95% 구간, 옅은 띠는 종목별 범위

실제 주가에서도 제4장의 패턴이 그대로 나타났다.

- Chronos-T5 수익률 입력은 17~18%로 구간이 붕괴하였다. 종목별로도 14~26%로, 어느 종목에서도 회복되지 않는다.
- TimesFM-2.5 1년 · 가격은 88%로 구간이 지나치게 넓다(10종목 모두 86~89%).
- 나머지 13개 TSFM 조건은 76~82%이다. 가장 목표에 가까운 것은 Chronos-2(79~82%)와 Moirai-2 1년 · 수익률(79.8%)이다.
- 미국과 한국의 차이는 작다. 같은 TSFM 조건에서 두 시장의 커버리지 차이는 Chronos-T5 수익률(한국이 약 4~5%p 높음)을 빼면 모두 2%p 이내이다. 종목별 범위도 대부분 4%p 폭 안에 들어온다. 시장이나 종목보다 모델 · 조건이 결과를 정한다.

기준 모형 중 RW 1년은 83.0%로 약간 넓고(미국 84.5%), RW 한 달은 79.6%, GARCH-t는 78.4%이다.

5.2 과거변동(RW) 대비 분위수 손실 (H6)

커버리지는 구간 하나만 본다. 분포 전체의 정확도는 9개 분위수의 분위수 손실로 본다. H6은 "TSFM이 같은 과거 길이의 RW보다 분위수 손실이 작다"는 가설이다.

표 5-2. RW 대비 분위수 손실 개선율 (양수 = TSFM이 나음)

모델	조건	RW 대비 손실 개선(%)	Holm p	판정
Chronos-T5	한 달 · 수익률	-19.5	3.8e-50	반대(RW 우위)
Chronos-T5	한 달 · 가격	-5.5	2.7e-18	반대(RW 우위)
Chronos-T5	1년 · 수익률	-16.1	6.7e-43	반대(RW 우위)
Chronos-T5	1년 · 가격	-0.8	2.4e-02	반대(RW 우위)
Chronos-2	한 달 · 수익률	-7.3	1.4e-38	반대(RW 우위)
Chronos-2	한 달 · 가격	-5.9	1.2e-15	반대(RW 우위)
Chronos-2	1년 · 수익률	+0.9	4.3e-05	유의하나 작음
Chronos-2	1년 · 가격	-3.2	8.9e-09	반대(RW 우위)
TimesFM-2.5	한 달 · 수익률	-4.7	9.3e-27	반대(RW 우위)
TimesFM-2.5	한 달 · 가격	-9.8	5.7e-27	반대(RW 우위)
TimesFM-2.5	1년 · 수익률	-0.1	8.8e-01	차이 없음
TimesFM-2.5	1년 · 가격	-3.7	1.4e-13	반대(RW 우위)
Moirai-2	한 달 · 수익률	-3.8	1.7e-24	반대(RW 우위)
Moirai-2	한 달 · 가격	-7.9	2.1e-16	반대(RW 우위)
Moirai-2	1년 · 수익률	+0.3	1.8e-01	차이 없음
Moirai-2	1년 · 가격	-2.2	3.5e-06	반대(RW 우위)

주: 개선율 = 1 − (TSFM 손실 / RW 손실). 검정은 달력 월별 평균 손실 차이(114개월)의 t검정(양측), Holm 보정(16개 묶음). 판정 기준 2%.

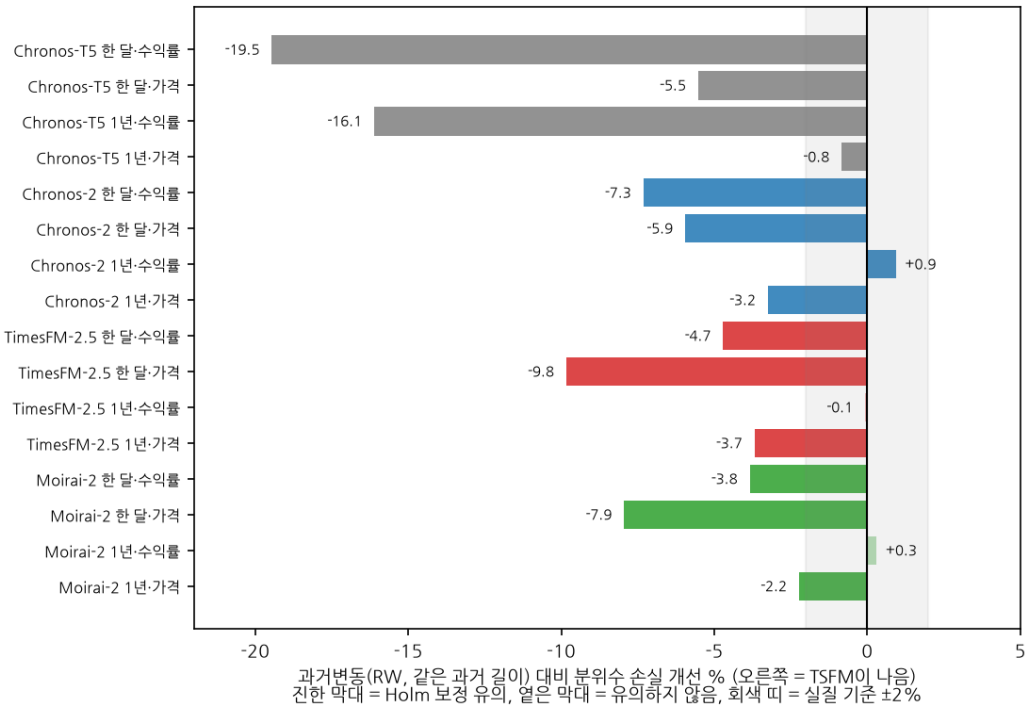


그림 5-2. 과거변동(RW) 대비 분위수 손실 개선율(H6)

진한 막대는 Holm 보정 후 유의

H6은 지지되지 않았다. 16개 조건 중 13개에서 TSFM의 분위수 손실이 RW보다 유의하게 컸고(개선율 -0.8 ~ -19.5%), 2개 조건(TimesFM 1년 · 수익률, Moirai-2 1년 · 수익률)은 차이가 없었으며, Chronos-2 1년 · 수익률만 개선율 +0.9%로 손실이 유의하게 작았으나 실질 기준(2%)에는 미치지 못하였다.

이 결과는 다음과 같이 해석할 수 있다. 첫째, 이 결과는 점 예측에서 보고된 결과(Rahimikia 외, 2025; Noguer i Alonso, Franklin, 2026)가 분포 예측에서도 성립함을 보여 준다. 일별 주가 수익률은 방향을 거의 예측할 수 없으므로(5.5절의 자기상관 참조), 정답에 가장 가까운 것은 최근 변동 크기를 기반으로 산출한 분포이며, RW가 바로 이에 해당한다. 둘째, 1년 과거를 수익률로 넣은 조건(Chronos-2, TimesFM, Moirai-2)에서 TSFM은 RW와 같은 수준에 도달하였다. TSFM은 별도 학습 없이도 이 단순하지만 강한 기준과 같은 정확도를 낼 수 있으나, 그보다 나아지지는 않았다. 반대로 과거 한 달만 보거나 가격을 넣은 조건에서는, Chronos-T5를 제외한 9개 조건에서 RW보다 손실이 2~10%

켰다. Chronos-T5는 수익률 입력에서 손실이 16~20% 더 켰는데, 4.2절에서 본 구간 붕괴가 분포 전체의 정확도에도 그대로 나타난 것이다.

5.3 모델 공개 이후 기간 점검

TSFM은 대규모 공개 시계열로 사전학습되었으므로, 평가 기간의 주가가 학습 데이터에 들어 있을 수 있다(누출). 이를 점검하기 위해 각 모델이 공개된 이후 기간만 따로 계산하였다.

표 5-3. 모델 공개 이후 기간의 결과

모델	조건	공개 후 시작일	예측 수	커버리지(%) (전체 → 공개 후)	RW 대비 개선(%) (전체 → 공개 후)
Chronos-T5	한 달 · 수익률	2024-04-01	4,291	16.9 → 16.2	-19.5 → -19.5
Chronos-T5	한 달 · 가격	2024-04-01	4,291	76.5 → 75.9	-5.5 → -6.5
Chronos-T5	1년 · 수익률	2024-04-01	4,291	17.6 → 15.8	-16.1 → -17.3
Chronos-T5	1년 · 가격	2024-04-01	4,291	76.2 → 74.6	-0.8 → -2.1
Chronos-2	한 달 · 수익률	2025-11-01	1,295	81.8 → 82.2	-7.3 → -7.1
Chronos-2	한 달 · 가격	2025-11-01	1,295	81.1 → 80.7	-5.9 → -9.1
Chronos-2	1년 · 수익률	2025-11-01	1,295	79.1 → 78.3	+0.9 → +0.2
Chronos-2	1년 · 가격	2025-11-01	1,295	80.0 → 79.2	-3.2 → -5.0
TimesFM-2.5	한 달 · 수익률	2025-10-01	1,478	78.2 → 77.0	-4.7 → -4.5
TimesFM-2.5	한 달 · 가격	2025-10-01	1,478	77.8 → 77.0	-9.8 → -13.7
TimesFM-2.5	1년 · 수익률	2025-10-01	1,478	77.2 → 71.8	-0.1 → -0.8
TimesFM-2.5	1년 · 가격	2025-10-01	1,478	87.7 → 84.0	-3.7 → -6.6
Moirai-2	한 달 · 수익률	2025-09-01	1,678	77.1 → 75.3	-3.8 → -3.2
Moirai-2	한 달 · 가격	2025-09-01	1,678	78.7 → 77.5	-7.9 → -15.4
Moirai-2	1년 · 수익률	2025-09-01	1,678	79.8 → 76.0	+0.3 → +0.0
Moirai-2	1년 · 가격	2025-09-01	1,678	82.1 → 80.8	-2.2 → -2.5

공개 이후에도 패턴은 같다. Chronos-T5 수익률의 붕괴(16%), TimesFM 1년 · 가격의 과대(84%)가 그대로 나타나고, RW 대비 손실은 전체 기간과 비슷하거나 약간 더 크다. TimesFM 1년 · 수익률(77.2 → 71.8%)과 Moirai-2 1년 · 수익률(79.8 → 76.0%)은 커버리지가 3~5%p 떨어졌는데, 공개 이후 기간이

1,300~1,700건(약 1년)으로 짧고 2025년 하반기 이후의 시장 상황이 함께 반영된 것이어서 원인을 단정할 수 없다. 적어도 "학습 데이터에 들어 있던 기간이라서 좋아 보였다"는 증거는 없다.

5.4 합성 데이터 실험과 실증 결과의 대응

제4장의 합성 데이터 실험에서 오차는 대부분 모델·설정에서 오고 금융 특성의 효과는 작았다. 그렇다면 실제 주가의 커버리지는 특성이 하나도 없는 L1의 커버리지로 상당 부분 예측되어야 한다. 분석 결과는 이를 뒷받침한다.

- 16개 TSFM 조건과 기준 모형 3개를 합한 19개에서 합성 L1 커버리지와 실제 커버리지의 상관은 0.998이다(Chronos-T5 수익률이 극단값이므로 이를 빼도 0.90).
- Chronos-T5 수익률 2개를 뺀 17개 조건에서 두 값의 차이는 평균 1.0%p, 최대 3.6%p(RW 1년: 79.4 → 83.0%)이다. 19개 전체로는 평균 1.2%p이다.

실제 주가에는 군집·꼬리·국면 전환이 모두 섞여 있는데도, 정규분포(L1)에서 측정한 커버리지와 평균 약 1%p의 차이만을 보인다. 이는 제4장의 결론, 즉 예측구간의 오차를 정하는 것은 금융 특성보다 모델과 입력 설정이라는 해석을 실제 데이터가 뒷받침한다는 뜻이다. 또한 실측 기반 합성 데이터 실험이 실제 주가의 커버리지를 평균 1.0%p(최대 3.6%p) 차이로 재현했다는 것은, 새 모델이나 입력 설정을 실제 데이터에 쓰기 전에 합성 데이터 점검으로 잘못된 설정을 걸러낼 수 있다는 뜻이다. 다만 이 대응은 본 연구의 10종목과 80% 구간에서 확인한 것이다.

5.5 탐색 분석: 예측구간과 투자 성과

> 이 절은 사전등록 밖의 탐색 분석이다. 분석 규칙은 계산 전에 별도 분석 계획으로 사전 고정하였고, 새 예측 없이 본 실행의 실제 주식 예측만 사용하였다.

예측구간의 통계적 평가와 별개로, 그 구간이 실제 투자와 위험 관리 규칙에서 어떻게 작동하는지도 확인할 필요가 있다. 이 절은 "예측구간의 질이 투

자 성과와 어떻게 연결되는가"를 세 가지 단순한 규칙으로 살펴본다. 공통 가정은 다음과 같다. 전날까지의 정보로 그날 비중을 정해 전날 종가에 체결하고, 10종목에 같은 금액을 나눈다. 거래비용은 미국 0.01%(한쪽), 한국은 수수료 0.015%(한쪽)에 매도 시 증권거래세·농특세를 날짜별 세율(0.30%에서 시작해 2025년 0.15%, 2026년 0.20%)로 적용하였다. 보정 구간은 실제 운용과 같은 정보 조건이 되도록 종목별로 끊지 않고 연속 적용하였다. 표본은 2017년 2월부터 2026년 9월까지이다.

5.5.1 방향 매매

규칙: 예측 중앙값($q_{0.5}$)이 0보다 크면 그날 보유(비중 1), 아니면 현금(비중 0).

표 5-4. 방향 매매 결과 (10종목 동일비중 포트폴리오)

전략	조건	연수익률(%) (비용 반영)	연수익률(%) (비용 제외)	샤프	최대낙폭(%)	평균 비중	연회전율(배)
계속 보유	-	25.4	25.4	1.25	-33.5	1.00	0
Chronos-T5	한 달 · 수익률	2.7	9.1	0.29	-37.4	0.50	87
Chronos-T5	한 달 · 가격	-1.0	5.8	-0.03	-36.0	0.45	93
Chronos-T5	1년 · 수익률	5.0	7.0	0.59	-18.2	0.31	47
Chronos-T5	1년 · 가격	0.6	9.1	0.11	-36.0	0.53	115
Chronos-2	한 달 · 수익률	2.1	8.3	0.24	-38.2	0.49	81
Chronos-2	한 달 · 가격	3.8	8.6	0.40	-27.5	0.43	64
Chronos-2	1년 · 수익률	16.4	18.4	1.10	-25.1	0.65	21
Chronos-2	1년 · 가격	6.0	11.0	0.55	-34.1	0.51	64
TimesFM-2.5	한 달 · 수익률	2.9	9.2	0.31	-36.6	0.53	80
TimesFM-2.5	한 달 · 가격	5.7	11.8	0.50	-32.3	0.47	77
TimesFM-2.5	1년 · 수익률	8.3	11.8	0.69	-28.1	0.58	47
TimesFM-2.5	1년 · 가격	3.3	8.4	0.34	-31.5	0.49	66
Moirai-2	한 달 · 수익률	1.4	6.9	0.19	-41.2	0.44	74
Moirai-2	한 달 · 가격	2.5	7.5	0.29	-31.9	0.41	66
Moirai-2	1년 · 수익률	6.0	10.7	0.51	-29.7	0.59	55
Moirai-2	1년 · 가격	8.7	12.9	0.68	-34.9	0.65	48
과거변동(RW)	한 달 · 수익률	12.0	13.9	0.99	-29.8	0.57	23
과거변동(RW)	1년 · 수익률	16.7	17.1	1.08	-25.4	0.69	5
GARCH-t	1년 · 수익률	20.7	21.2	1.27	-23.1	0.66	4

모든 TSFM 방향 매매가 계속 보유보다 못하였다. 비용을 넣으면 연 -1.0~16.4%로 계속 보유(25.4%)에 크게 못 미쳤고, 비용을 빼도 5.8~18.4%였다. 방향을

맞힌 비율은 49.3~51.6%로, 매일 "오른다"고 답했을 때의 적중률(실제 상승일 비율 50.1%)과 다르지 않다. 실제 수익률의 하루 자기상관은 종목별로 -0.10~+0.04로, 어제의 움직임이 오늘의 방향을 거의 알려 주지 않는다. 방향 신호가 자주 바뀌어 연 회전율이 21~115배에 달하므로 비용이 성과를 크게 깎는다.

5.5.2 변동성 목표 비중 조절

규칙: 80% 구간 폭으로 내일의 변동(σ^ = 폭 ÷ 2.5631)을 추정하고, 비중을 w = min(1, 1% ÷ σ^)로 정한다. 하루 변동을 1% 안팎으로 맞추려는 변동

성 목표 전략이며, 차입은 하지 않는다. 이 규칙은 방향이 아니라 구간의 폭, 즉 이 연구가 평가한 대상을 직접 쓴다.

표 5-5. 비중 조절(변동성 목표 1%) 결과 (비용 반영, 원래 구간 / 보정 구간)

전략	조건	샤프	최대낙폭(%)	실현변동/목표	RW 대비 샤프 차(보정) [95% 구간]
계속 보유	-	1.25	-33.5	2.26	-
Chronos-T5	한 달 · 수익률	1.24 / 1.12	-34.0 / -24.3	2.21 / 1.11	-0.23 [-0.36, -0.09] ×
Chronos-T5	한 달 · 가격	1.17 / 1.15	-22.4 / -22.1	1.12 / 1.06	-0.20 [-0.32, -0.09] ×
Chronos-T5	1년 · 수익률	1.25 / 1.17	-34.2 / -21.3	2.23 / 1.14	-0.16 [-0.24, -0.07] ×
Chronos-T5	1년 · 가격	1.20 / 1.24	-25.1 / -23.5	1.22 / 1.12	-0.09 [-0.19, +0.00]
Chronos-2	한 달 · 수익률	1.30 / 1.33	-19.0 / -19.8	0.99 / 1.05	-0.02 [-0.11, +0.06]
Chronos-2	한 달 · 가격	1.21 / 1.23	-22.6 / -24.0	1.03 / 1.07	-0.12 [-0.27, +0.04]
Chronos-2	1년 · 수익률	1.26 / 1.32	-21.3 / -22.5	1.15 / 1.13	-0.01 [-0.09, +0.07]
Chronos-2	1년 · 가격	1.20 / 1.25	-22.6 / -23.5	1.09 / 1.09	-0.07 [-0.16, +0.01]
TimesFM-2.5	한 달 · 수익률	1.33 / 1.33	-20.8 / -20.2	1.09 / 1.07	-0.02 [-0.08, +0.05]
TimesFM-2.5	한 달 · 가격	1.32 / 1.30	-20.7 / -21.3	1.09 / 1.05	-0.05 [-0.17, +0.07]
TimesFM-2.5	1년 · 수익률	1.27 / 1.31	-21.1 / -22.0	1.20 / 1.12	-0.01 [-0.07, +0.04]
TimesFM-2.5	1년 · 가격	1.21 / 1.30	-17.1 / -23.1	0.88 / 1.10	-0.03 [-0.12, +0.06]
Moirai-2	한 달 · 수익률	1.30 / 1.32	-22.2 / -20.6	1.14 / 1.08	-0.02 [-0.11, +0.06]
Moirai-2	한 달 · 가격	1.20 / 1.21	-24.9 / -24.4	1.08 / 1.07	-0.14 [-0.29, +0.02]
Moirai-2	1년 · 수익률	1.27 / 1.37	-19.7 / -21.6	1.12 / 1.13	+0.04 [-0.01, +0.10]
Moirai-2	1년 · 가격	1.27 / 1.28	-20.8 / -22.2	1.04 / 1.10	-0.04 [-0.14, +0.05]
과거변동(RW)	한 달 · 수익률	1.32 / 1.35	-20.4 / -20.5	1.12 / 1.12	비교 기준(한 달)
과거변동(RW)	1년 · 수익률	1.18 / 1.33	-21.4 / -21.0	1.09 / 1.14	비교 기준(1년)
GARCH-t	1년 · 수익률	1.29 / 1.31	-21.0 / -22.6	1.17 / 1.14	-0.02 [-0.09, +0.05]

주: 각 칸은 '원래 구간 / 보정 구간'. RW 대비는 같은 과거 길이의 RW 보정 구간을 쓴 같은 전략과 비교(달력 월 블록 부트스트랩 2,000회). × = 95% 구간이 0보다 작음(RW보다 낮음), ○ = 0보다 큼(해당 없음). 원래 구간끼리의 비교에서 유의하게 낮은 경우는 Chronos-T5 한 달 · 가격 1건이다. 계속 보유의 실현변동/목표는 참고값.

비중 조절은 수익률을 낮추는 대신 위험을 크게 줄였다. 계속 보유의 최대 낙폭 -33.5%가 비중 조절에서는 -17~-25%로 줄었고, 샤프 비율은 1.12~1.37로 계속 보유(1.25)와 비슷하거나 높았다. 그러나 TSFM 구간을 쓴 경우가 RW 구간을 쓴 경우보다 나은 조건은 없었고(샤프 차이의 95% 구간이 0보다 큰 경우

0개), Chronos-T5의 3개 조건(보정 구간 기준; 원래 구간은 한 달 · 가격 1개 조건)에서는 샤프 비율이 유의하게 낮았다. 5.2절에서 TSFM의 분포 정확도가 RW 수준이었던 것과 같은 결과이다.

여기서 구간이 잘못되었을 때의 비용이 분명하게 드러난다. Chronos-T5 수익률 입력의 원래 구간은 폭이 실제의 7분의 1이므로 "내일 변동이 아주 작다"고 판단해 늘 비중 1을 택하였다. 그 결과 실현 변동이 목표의 2.2배였고 낙폭도 계속 보유와 같았다(-34%). 같은 예측에 사후보정을 하면 실현 변동이 목표의 1.1배로 돌아오고 낙폭은 -21~-24%로 줄었다. 위험 관리에 쓰는 구간에서 커버리지가 맞지 않으면, 전략은 의도한 위험 수준을 지키지 못한다.

5.5.3 VaR 10% 백테스트

규칙: 80% 구간의 하단($q_{0.1}$)을 "10% 확률로만 이보다 더 잃는다"는 위험 한도(VaR 10%)로 쓰고, 실제로 넘은 날의 비율(위반율)을 검정한다. 위반율이

10%인지는 Kupiec 검정, 위반이 몰려 오지 않는지는 Christoffersen 독립성 검정으로 보았다(종목별, 유의수준 5%).

표 5-6. 위험 한도(VaR 10%) 백테스트 (보정 전 → 보정 후)

모델	조건	위반율(%) (목표 10%)	위반율 검정 통과 (종목 수)	독립성 검정 통과 (종목 수)
Chronos-T5	한 달 · 수익률	42.4 → 9.9	0 → 9	0 → 8
Chronos-T5	한 달 · 가격	9.8 → 8.6	10 → 2	9 → 8
Chronos-T5	1년 · 수익률	39.5 → 9.2	0 → 8	8 → 9
Chronos-T5	1년 · 가격	11.7 → 9.9	4 → 10	9 → 9
Chronos-2	한 달 · 수익률	8.8 → 9.9	5 → 10	8 → 7
Chronos-2	한 달 · 가격	9.3 → 9.5	5 → 7	0 → 3
Chronos-2	1년 · 수익률	10.3 → 10.0	10 → 10	8 → 9
Chronos-2	1년 · 가격	9.0 → 9.1	6 → 7	2 → 6
TimesFM-2.5	한 달 · 수익률	10.3 → 9.7	10 → 9	7 → 5
TimesFM-2.5	한 달 · 가격	9.8 → 9.0	10 → 5	0 → 0
TimesFM-2.5	1년 · 수익률	11.3 → 10.0	5 → 10	8 → 10
TimesFM-2.5	1년 · 가격	5.5 → 9.0	0 → 6	5 → 8
Moirai-2	한 달 · 수익률	11.9 → 10.5	0 → 10	6 → 7
Moirai-2	한 달 · 가격	10.1 → 9.4	7 → 8	0 → 0
Moirai-2	1년 · 수익률	10.8 → 10.8	9 → 10	10 → 10
Moirai-2	1년 · 가격	9.2 → 10.2	8 → 9	6 → 9
과거변동(RW)	한 달 · 수익률	9.8 → 9.9	10 → 10	4 → 6
과거변동(RW)	1년 · 수익률	8.5 → 10.0	3 → 10	3 → 9
GARCH-t	1년 · 수익률	10.6 → 9.9	7 → 10	7 → 10

주: 검정 통과 종목 수는 10개 종목 중 유의수준 5%에서 기각되지 않은 종목의 수. 위반율 검정은 Kupiec, 독립성 검정은 Christoffersen.

결과는 사후보정의 실무적 의미를 보여 준다. Chronos-T5 수익률의 원래 하단은 위반율 40~42%로 위험 한도로 쓸 수 없지만, 보정 후 9~10%로 돌아왔다. 19개 모델 · 조건 중 10종목 중 8종목 이상이 위반율 검정을 통과한 경우는 보정 전 7개에서 보정 후 14개로 늘었다. 다만 보정 전에 이미 위반율이 맞던 일

부 조건(Chronos-T5 한 달 · 가격, TimesFM 한 달 · 가격)은 보정 후 위반율이 8.6~9.0%로 오히려 10%보다 낮아져 통과 종목이 줄었다(10 → 2, 10 → 5). 보정은 이탈 기록에 따라 구간을 계속 조정하므로, 이미 맞던 구간에는 작은 흔들림을 더할 수 있다. 반면 한 달 · 가격 조건(Chronos-2, Moirai-2, TimesFM)은 보정 후에도 위반이 몰려 오는 문제(독립성 통과 0~3종목)가 남았다. 사후보정은 위반의 비율은 맞추지만 위반이 언제 오는지까지는 고치지 못한다.

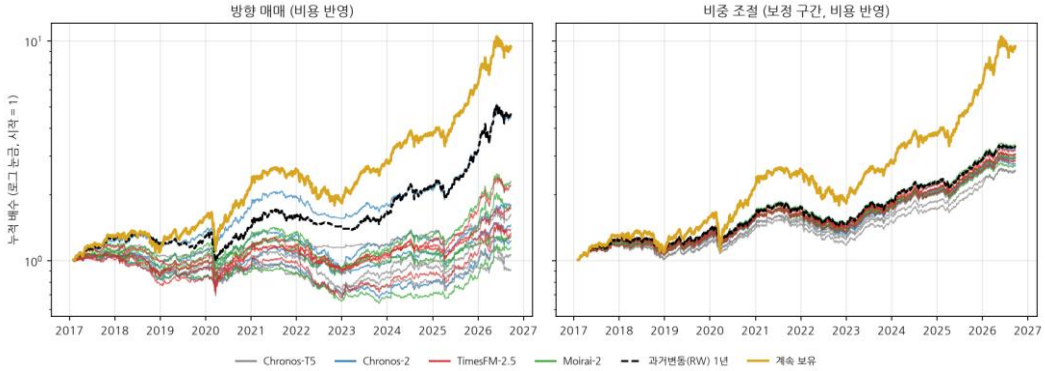


그림 5-3. 10종목 동일비중 포트폴리오의 누적 수익(2017-02~2026-09, 탐색 분석)

5.5.4 해석과 한계

세 분석을 합치면 다음과 같다. 예측 중앙값의 부호로 매매하는 단순 규칙으로는 거래비용을 반영한 뒤 계속 보유를 넘는 수익을 내기 어려웠다(5.5.1절). 그러나 예측구간을 위험 크기 측정에 쓰면 낙폭을 줄이는 실질적 효과가 있었다(5.5.2절). 이 효과는 TSFM 구간과 RW 구간이 비슷하였고(RW보다 나은 조건 없음), 구간의 커버리지가 맞을 때에만 의도대로 나타났다(5.5.2~5.5.3절). 이것이 이 연구가 방향이 아닌 예측구간을 평가한 이유이며, 제6장의 사후보정이 실무적으로 중요한 이유이다.

이 분석은 탐색적이며 다음 한계가 있다. 전날 종가 체결은 실제보다 유리한 가정이고, 시장 충격 비용과 세금 외 비용은 넣지 않았다. 대상은 2017년 기준 대형주 10종목이며 표본 기간에 강세장(계속 보유 연 25.4%)이 포함되어 있어, 현금 비중을 갖는 전략은 수익률에서 불리할 수밖에 없다.

5.6 소결

두 번째 연구 질문(RQ2)에 대한 실증 결과를 요약하면 다음과 같다.

1. 실제 주가에서도 오차는 모델과 입력 설정에서 온다. 실제 10종목의 보정 전 커버리지는 17~88%로, 특성 없는 합성 데이터(L1)의 커버리지와 평균 1.0%p(구간이 붕괴한 2개 조건 제외, 전체 1.2%p) 차이였다. 미국과 한국, 종목 간 차이는 모델·조건 간 차이보다 작았다(5.1절, 5.4절).
2. 분포 정확도는 RW 수준이다. 분위수 손실은 16개 조건 중 13개에서 RW보다 컸고, Chronos-T5를 제외한 세 모델의 1년·수익률 조건에서 RW와 같은 수준이었다(H6 미지지). 모델 공개 이후 기간만 보아도 같았다(5.2~5.3절).
3. 예측구간은 위험 측정에 쓸 때 의미가 있다. 탐색 분석에서 중앙값 부호로 매매하는 규칙은 계속 보유보다 못했지만, 구간 폭으로 비중을 조절하면 최대 낙폭이 -33.5%에서 -17~-25%로 줄었다. 이 효과는 구간의 커버리지가 맞을 때에만 의도대로 나타났다(5.5절).

이 결과는 제6장의 질문으로 이어진다. 오차가 모델과 설정에서 온다면, 모델을 고치지 않고 출력 구간만 조정해 이를 바로잡을 수 있는가?

제 6 장 사후보정을 통한 커버리지 복원 (RQ3)

제4장과 제5장에서 TSFM 예측구간의 오차는 모델·입력 설정에 따라 14%에서 88%까지 다양하였다. 오차의 원인이 모델 내부에 있다면 모델을 고치거나 다시 학습시켜야 할 것처럼 보이지만, 실무에서 사전학습 모델을 고치는 것은 어렵다. 본 장에서는 모델은 그대로 두고 출력 구간만 조정하는 사후보정(ACI-CQR, 3.5절)이 이 오차를 바로잡는지를 검증한다(H5). 6.1절은 합성 데이터, 6.2절은 실제 주식, 6.3절은 보정의 비용(구간 폭), 6.4절은 대조군, 6.5절은 GARCH-t 비정상 값 2건의 민감도를 다룬다.

판정 기준(사전등록): 보정 후 커버리지의 90% 신뢰구간이 [77%, 83%] 안에 완전히 들어오면 "복원"이다.

6.1 합성 데이터에서의 보정 결과

표 6-1. 합성 데이터의 보정 전후 커버리지 (17개 시나리오의 범위)

모델	조건	보정 전(%)	보정 후(%)	복원 시나리오	대조군(%)	폭 배율(보정/원래)
Chronos-T5	한 달 · 수익률	14.1~15.7	80.0~80.5	17/17	81.9~85.1	8.52~9.44
Chronos-T5	한 달 · 가격	74.5~78.1	79.8~80.4	17/17	81.7~83.8	1.14~1.24
Chronos-T5	1년 · 수익률	13.9~15.3	79.7~80.5	17/17	81.5~85.5	8.03~9.44
Chronos-T5	1년 · 가격	74.4~77.5	80.0~80.4	17/17	81.8~84.9	1.14~1.28
Chronos-2	한 달 · 수익률	80.5~82.0	80.0~80.3	17/17	82.2~84.9	1.01~1.10
Chronos-2	한 달 · 가격	79.2~81.2	80.1~80.3	17/17	82.2~84.2	1.06~1.12
Chronos-2	1년 · 수익률	77.1~80.8	80.1~80.4	17/17	81.7~85.0	1.06~1.18
Chronos-2	1년 · 가격	77.3~83.0	80.1~80.5	17/17	81.1~84.5	0.99~1.15
TimesFM-2.5	한 달 · 수익률	76.5~79.5	79.9~80.4	17/17	82.1~84.7	1.10~1.22
TimesFM-2.5	한 달 · 가격	76.0~79.1	80.2~80.5	17/17	82.2~84.6	1.12~1.24
TimesFM-2.5	1년 · 수익률	77.3~80.0	80.0~80.4	17/17	81.5~85.7	1.04~1.28
TimesFM-2.5	1년 · 가격	86.8~88.4	80.2~80.5	17/17	81.3~84.6	0.81~0.92
Moirai-2	한 달 · 수익률	75.7~78.8	80.2~80.4	17/17	82.5~84.5	1.14~1.22
Moirai-2	한 달 · 가격	75.4~80.4	79.8~80.5	17/17	81.9~84.4	1.08~1.22
Moirai-2	1년 · 수익률	79.7~82.0	80.0~80.3	17/17	81.8~85.5	1.01~1.16
Moirai-2	1년 · 가격	77.8~81.1	80.1~80.7	17/17	81.6~84.4	1.05~1.19
과거변동(RW)	한 달 · 수익률	75.9~82.0	80.2~80.4	17/17	82.1~84.4	1.03~1.17
과거변동(RW)	1년 · 수익률	79.4~86.4	80.0~80.3	17/17	81.4~85.3	0.87~1.06
GARCH-t	1년 · 수익률	78.4~80.1	80.0~80.4	17/17	67.2~85.2	0.74~1.16
오라클 모형	–	79.3~80.2	80.1~80.4	17/17	81.6~83.3	1.05~1.09

주: 폭 배율 = 보정 후 평균 폭 ÷ 보정 전 평균 폭. 대조군은 6.4절 참조.

모든 경우가 복원되었다. TSFM 16개 조건 × 17개 시나리오 = 272개, 기준 모형 3개를 더한 323개, 오라클 모형까지 340개 모두에서 보정 후 커버리지는 79.7~80.7%였다. 보정 전 14%(Chronos-T5 수익률)든 88%(TimesFM 1년 · 가격)든, 각 금융 특성의 강도와 무관하게 모두 80% 수준으로 복원되었다.

특히 중요한 것은 방향이 반대인 두 오차를 같은 방법이 고쳤다는 점이다. 구간이 너무 좁은 경우(Chronos-T5, 한 달 조건들)에는 넓히고, 너무 넓은 경

우(TimesFM 1년 · 가격)에는 좁혔다(폭 배율 0.81~0.92). 사후보정은 구간을 일률적으로 넓히는 방법이 아니라 실제 이탈 기록에 따라 양방향으로 조정하는 방법이다.

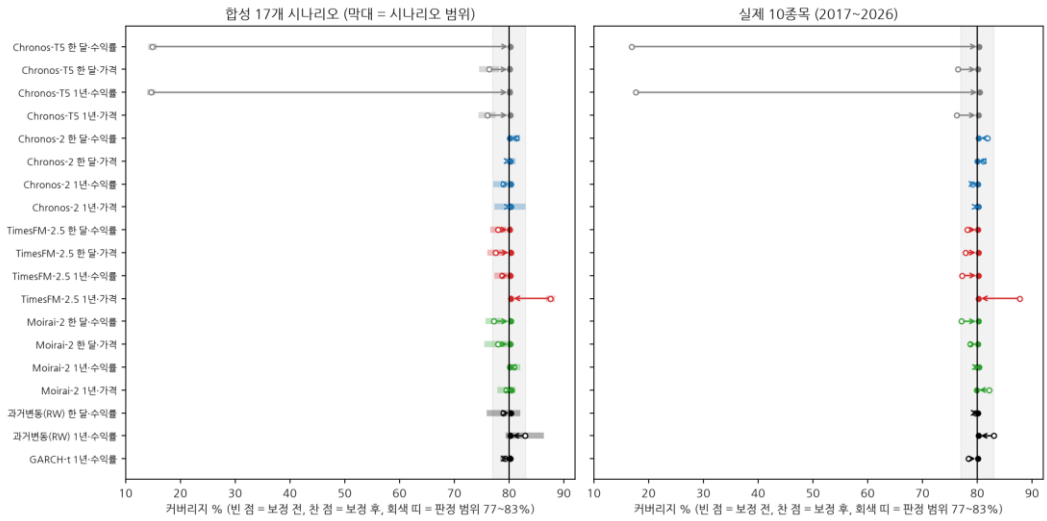


그림 6-1. 사후보정(ACI-CQR) 전후 커버리지

빈 점은 보정 전, 찬 점은 보정 후

6.2 실제 주식에서의 보정 결과

표 6-2. 실제 10종목의 보정 전후 커버리지

모델	조건	보정 전(%)	보정 후(%) [90% 구간]	판정	대조군(%)	연속 보정(%)	폭 배율(연속)
Chronos-T5	한 달 · 수익률	16.9	80.3 [79.7, 81.0]	복원	82.1	80.0	7.68
Chronos-T5	한 달 · 가격	76.5	80.1 [79.6, 80.6]	복원	83.0	80.0	1.14
Chronos-T5	1년 · 수익률	17.6	80.4 [79.8, 81.1]	복원	80.0	79.9	7.50
Chronos-T5	1년 · 가격	76.2	80.2 [79.5, 80.8]	복원	83.2	80.0	1.18
Chronos-2	한 달 · 수익률	81.8	80.2 [79.6, 80.7]	복원	83.2	80.0	1.00
Chronos-2	한 달 · 가격	81.1	80.0 [79.6, 80.5]	복원	83.1	80.0	1.02
Chronos-2	1년 · 수익률	79.1	80.1 [79.5, 80.7]	복원	83.2	80.0	1.08
Chronos-2	1년 · 가격	80.0	80.2 [79.7, 80.8]	복원	82.8	80.0	1.05
TimesFM-2.5	한 달 · 수익률	78.2	80.1 [79.5, 80.8]	복원	82.8	80.0	1.09
TimesFM-2.5	한 달 · 가격	77.8	80.2 [79.7, 80.7]	복원	83.1	80.0	1.12
TimesFM-2.5	1년 · 수익률	77.2	80.2 [79.6, 80.9]	복원	83.1	79.9	1.12
TimesFM-2.5	1년 · 가격	87.7	80.2 [79.6, 80.8]	복원	82.9	80.0	0.83
Moirai-2	한 달 · 수익률	77.1	80.2 [79.6, 80.8]	복원	83.3	80.0	1.12
Moirai-2	한 달 · 가격	78.7	80.1 [79.6, 80.7]	복원	83.2	80.0	1.08
Moirai-2	1년 · 수익률	79.8	80.3 [79.6, 80.9]	복원	83.3	80.0	1.06
Moirai-2	1년 · 가격	82.1	79.9 [79.4, 80.4]	복원	83.5	80.0	1.01
과거변동(RW)	한 달 · 수익률	79.6	80.0 [79.3, 80.8]	복원	82.9	80.0	1.04
과거변동(RW)	1년 · 수익률	83.0	80.2 [79.4, 80.9]	복원	82.5	79.8	0.96
GARCH-t	1년 · 수익률	78.4	80.1 [79.5, 80.7]	복원	83.2	80.0	1.10

주: 보정 후 90% 구간은 달력 월 클러스터 부트스트랩 2,000회. 연속 보정은 에피소드를 끊지 않고 종목별로 처음부터 끝까지 이어서 적용한 보조 분석(23,932건). 폭 배율은 연속 보정 기준.

실제 주가에서도 19개 모델·조건이 모두 복원되었다(보정 후 79.9~80.4%). 미국과 한국을 나눠 보아도 19개 모두 복원이다(미국 79.8~80.4%, 한국 79.9~80.5%). 에피소드를 끊지 않고 이어서 보정한 경우에도 79.8~80.0%로, 사후보정의 효과는 에피소드 길이 설정에 의존하지 않는다.

이로써 RQ3의 핵심 가설 H5는 합성·실제 모두에서 예외 없이 지지되었다. 제4장과 제5장의 결론과 합치면, TSFM 예측구간의 오차는 크고 모델·설정마다 방향이 다르지만, 그 오차는 단순한 사후보정으로 일관되게 고칠 수 있다.

6.3 보정에 따른 구간 폭 변화

커버리지를 복원하는 데에는 구간 폭의 확대가 수반되며, 이를 원래 구간과 이상적인 구간의 두 기준으로 비교하였다.

① 원래 구간과 비교(폭 배율, 표 6-1·6-2)

- 이미 목표에 가까웠던 조건(Chronos-2, Moirai-2 1년 등)은 폭이 거의 변하지 않았다(1.0~1.2배). 보정은 필요 없는 곳에서 구간을 크게 바꾸지 않는다.
- 약간 좁았던 조건(TSFM 한 달 조건 대부분, Chronos-T5 가격)은 1.1~1.3배 넓어졌다.
- 너무 넓었던 TimesFM 1년·가격은 0.8~0.9배로 좁아졌다. 보정으로 목표에 맞으면서 더 좁은 구간을 얻었다.
- 붕괴했던 Chronos-T5 수익률은 7.5~9.4배 넓어졌다.

② 이상적인 구간과 비교(합성 데이터, 오라클 모형 폭 대비)

합성 데이터에서는 참 분포를 알므로 "80%를 맞추는 가장 좁은 구간"인 오라클 모형의 폭과 비교할 수 있다. 보정 후 TSFM 구간의 폭은 시나리오에 따라 오라클 모형의 1.06~1.48배였다. 보정된 구간은 80%를 맞추지만 이상적인

구간보다 6~48% 넓다. 과거 1년 조건(1.06~1.24배)이 한 달 조건(1.17~1.48배)보다 이상에 가까웠고, 오라클 모형 자체에 보정을 적용한 경우도 1.05~1.09배로 약간 넓어졌다. 이 차이는 정확한 구간을 모르는 상태에서 과거 이탈 기록만으로 80%를 맞추는 데 따르는 비용이다.

특히 Chronos-T5 수익률도 보정 후에는 오라클 모형의 1.06~1.38배로 다른 모델과 비슷한 범위에 들어왔다. 다만 이는 80% 구간의 상·하한(양 끝 분위수)에 한정된 결과이다. 보정은 나머지 분위수를 바꾸지 않으므로, 이 모델의 분포 전체 정확도(제5장 H6, RW 대비 -16~-20%)는 개선되지 않는다.

6.4 일괄 확대 대조군과의 비교

보정의 효과가 단순히 구간을 넓힌 결과인지 확인하기 위해, 원래 구간을 일괄 확대해 평균 폭을 보정 후 구간과 같게 만든 대조군과 비교하였다(3.5.2절). 대조군의 배율은 결과를 본 뒤에야 알 수 있는 값이므로, 대조군은 미래 정보를 일부 쓴, 보정보다 유리한 비교 대상에 해당한다.

대조군의 커버리지는 합성 81~86%, 실제 80~84%로 80%보다 높았다(표 6-1, 6-2). 같은 평균 폭으로 더 많이 맞혔다는 뜻이므로, 폭을 쓰는 효율만 보면 일괄 확대가 보정보다 낫다. 보정은 이탈 기록에 따라 매일 폭을 넓히고 좁히는데, 이 흔들림의 일부는 커버리지에 기여하지 못하고 폭만 늘린다.

그러나 일괄 확대는 실제로는 쓸 수 없다. 몇 배로 넓혀야 하는지는 결과를 보기 전에는 알 수 없고, 필요한 배율은 모델·조건에 따라 0.8배에서 9배까지 다르다(6.3절). 보정의 가치는 이 배율을 모르는 상태에서 매일의 실제값만 보고 80%에 도달한다는 데 있다. 동시에 이 결과는 보정의 폭 효율을 높일 여지가 있음을 보여 준다(제7장 향후 연구).

한편 표 6-1에서 GARCH-t의 합성 대조군 최솟값이 67.2%로 낮게 나타난 것은 6.5절에서 다룰 비정상 추정치 2건이 평균 폭과 확대 배율을 왜곡한 결과이다.

6.5 GARCH-t 비정상 값에 대한 민감도 분석

4.1절에서 밝혔듯 GARCH-t는 합성 데이터 136,000건 중 2건(전환크기 L3 계열 79의 66일째, 꼬리 L2 계열 86의 64일째)에서 추정 실패로 구간 끝이 -25,042 또는 1,954만 같은 값을 냈다. 사전에 정한 대체 규칙(유한하지 않음, 분산 ≤ 0, ν ≤ 2)에 걸리지 않는 형태였으며, 두 건 모두 채점일이다. 사후 민감도 분석으로 이 2건만 같은 날의 RW 1년 예측으로 바꾸어 다시 계산하였다.

표 6-3. GARCH-t 비정상 값 2건 대체 전후 비교 (합성 데이터 17개 시나리오 전체)

항목	사전등록 그대로	2건 대체(사후)
커버리지	79.31%	79.31%
평균 구간 폭(%p)	17,318	4.87
평균 분위수 손실(×100)	3,953	0.612

커버리지는 사실상 같고, 평균 폭과 손실 같은 평균값만 2건에 의해 크게 왜곡되었다. 가설 검정(H1~H6)에는 GARCH-t를 쓰지 않았으므로 결론은 바뀌지 않는다. 본문 표의 GARCH-t 커버리지는 그대로 사용하며, 평균 폭·손실이 필요한 곳에는 대체 후 값을 함께 적는다.

6.6 실무적 의미

제5.5절의 탐색 분석은 보정의 의미를 투자 규칙으로 보여 준다. Chronos-T5 수익률 입력의 원래 구간을 위험 한도(VaR 10%)로 쓰면 10번 중 4번 넘게 한도를 넘었지만, 보정 후에는 10번 중 1번으로 돌아왔다. 변동성 목표 전략에서는 실현 변동이 목표의 2.2배에서 1.1배로 돌아왔다. 사후보정은 통계 지표만이 아니라 구간을 실제로 쓰는 의사결정에서도 오차를 바로잡는다.

반면 사후보정의 한계도 확인된다. 보정은 위반의 비율은 맞추지만 위반이 몰려 오는 문제(한 달·가격 조건)는 고치지 못했고, 80% 구간의 양 끝만 조정할 뿐 나머지 분위수(중앙값 등)는 바꾸지 않으므로 분포 전체의 정확도(H6)

를 높이지는 않는다. 한편 사전등록 밖의 관찰로, 1년 · 수익률 조건에서는 보정 후 4개 TSFM 모두 위반율 검정(8~10종목)과 독립성 검정(9~10종목)을 함께 통과하여 보정의 효과가 가장 안정적이었다(표 5-6).

6.7 소결

세 번째 연구 질문(RQ3)에 대한 실험 결과를 요약하면 다음과 같다.

1. 사후보정은 모든 경우에 평균 커버리지를 80%로 복원한다. 합성 340개, 실제 19개 모델 · 조건 모두 예외가 없고, 연속 적용에서도 같다. 다만 위반이 몰려 오는 문제는 일부 조건(한 달 · 가격)에 남는다(6.6절).
2. 오차의 방향과 무관하다. 좁은 구간은 넓히고, 넓은 구간은 좁힌다.
3. 비용은 구간 폭이다. 보정 후 구간은 이상적인 구간보다 6~48% 넓고, 과거 1년 조건이 한 달 조건보다 비용이 작다. 목표에 가까웠던 모델은 원래 구간을 거의 바꾸지 않고 80%를 맞춘다.
4. 폭 효율에는 개선 여지가 있다. 결과를 본 뒤 정한 배율로 일괄 확대하면 같은 평균 폭으로 더 높은 커버리지(80~86%)를 얻는다. 보정은 폭 효율이 이보다 낮지만, 필요한 배율을 미리 몰라도 80%에 도달한다.

제4장에서 오차의 주된 원인이 금융 특성이 아니라 모델 · 설정임을 보였고, 이 장에서 그 오차가 모델을 고치지 않고도 바로잡힌다는 것을 보였다. 두 결과는 함께 하나의 실무 지침이 된다. TSFM을 금융 위험 측정에 쓸 때는 모델과 입력 설정을 먼저 점검하고, 사후보정을 기본으로 덧붙여야 한다.

제 7 장 결론

7.1 연구 요약

본 연구는 사전학습 시계열 모델(TSFM)이 내는 금융 수익률 80% 예측구간이 명목 커버리지를 충족하는지, 지키지 못한다면 원인이 무엇이고 어떻게 고칠 수 있는지를 실측 기반 합성 데이터 통제 실험과 미국·한국 대형주 10종목 평가로 검증하였다. 표 7-1은 세 연구 질문에 대한 답을 정리한다.

표 7-1. 연구 질문별 가설 판정과 발견

연구 질문	가설	판정 및 핵심 발견	근거
RQ1 진단	H1 군집 → 하락	일부 지지(2개 조건 실질 하락). 커버리지를 낮춘 특성은 군집뿐	-2.0~-2.5%p
	H2 꼬리 → 하락	미지지, 반대 방향(9개 조건 유의한 상승). 80% 구간의 수학적 성질로 설명	t분포 이론 커버리지 82~87%
	H3a 전환 빈도 → 하락	미지지, 반대 방향(5개 조건 작은 상승). 혼합분포 효과로 설명	RW 1년 +5.5%p, TSFM 2%p 이내
	H3b 전환 크기 → 하락	미지지(유의한 변화 1개, 작은 상승). 전환 크기는 커버리지에 영향 없음	Wilcoxon, Holm 보정
	H4 축마다 다름	16개 중 9개 지지. 9개 모두 군집이 가장 불리	Friedman, Holm 보정
RQ2 실증 평가	H6 TSFM이 RW보다 정확	미지지(13개 조건 RW보다 손실 큼, 2개 차이 없음, 1개 작은 우위). Chronos-T5 외 1년·수익률 3개 조건은 RW 수준	분위수 손실 -19.5~+0.9%
RQ3 처방	H5 보정 후 80% 복원	전면 지지(합성 340개, 실제 19개)	보정 후 79.7~80.7%

가설 H1~H3b가 대부분 지지되지 않은 것은 실험의 실패가 아니라, 금융 특성보다 모델과 입력 설정이 오차를 정한다는 RQ1의 답 그 자체이다. 세 결과를 하나로 묶으면 다음과 같다. TSFM 예측구간의 오차는 크고 모델·설정마다 방향도 다르지만, 그 대부분은 금융 데이터의 특성이 아니라 모델과 입력 설정에서 오며, 실측 기반 합성 데이터 실험으로 미리 진단할 수 있다. 이 오차는 재학습 없는 사후보정으로 일관되게 바로잡힌다. 분포의 정확도는 RW 수준이므로, TSFM 예측구간은 수익률 예측보다 보정을 거친 위험 측정에 쓰는 것이 적절하다.

7.2 실무적 시사점

1. 입력 설정을 먼저 점검해야 한다. 선행연구(Rahimikia 외, 2025)처럼 수익률을 그대로 입력하면 Chronos-T5의 80% 구간은 실제 주가에서 17~18%만 맞아, 실제값의 80% 이상이 구간 밖에 놓였다. 같은 모델이라도 입력 형태(수익률·가격)와 과거 구간 길이에 따라 커버리지가 15%에서 88%까지 달라졌다(Chronos-T5 수익률 15% 대 가격 76%, TimesFM-2.5 1년·가격 88% 대 1년·수익률 77~79%). 특성이 없는 합성 데이터에서 커버리지를 사전에 측정해 보면 실제 주가에서의 커버리지를 평균 1.0%p(구간이 붕괴한 2개 조건 제외, 전체 1.2%p, 최대 3.6%p) 차이로 예측할 수 있었다(본 연구의 10종목, 5.4절). 따라서 실제 데이터에 쓰기 전에 간단한 점검으로 잘못된 설정을 걸러낼 수 있다.
2. 사후보정을 기본으로 붙여야 한다. ACI-CQR은 모델을 바꾸지 않고, 계산 비용이 거의 없으며, 모든 경우에 평균 커버리지를 80%로 복원하였다. 변동성 목표와 VaR 같은 실제 규칙에서도 보정 전후의 차이가 분명하였다(5.5절, 6.6절).
3. TSFM 예측구간은 방향 예측이 아니라 위험 측정에 쓰고, 입력 설정은 모델마다 점검해 골라야 한다. 일별 수익률에서 TSFM은 RW보다 나은 분포를 내지 못했고, 중앙값 부호로 매매하는 규칙도 계속 보유보다 못하였다. 가장 나은 설정도 모델마다 달라서, Chronos-T5를 제외한 세 모델은 1년·수익률 조건에서 RW와 같은 정확도를 보였지만 같은 조건에서 Chronos-T5는 구간이 붕괴하였다. TSFM 예측구간의 쓸모는 위험 크기 측정에 있으며, 설정 점검과 보정을 거쳤을 때 의도대로 작동한다.

7.3 한계

1. 80% 구간만 평가하였다. 일부 모델이 0.1~0.9 분위수만 내기 때문에 99% · 95% 같은 극단 구간은 평가하지 못하였다. 4.3.2절의 이론 계산(표 4-3)에서 꼬리가 두꺼울수록 80% 구간은 넓어지지만 99% 구간은 반대로 좁아지고 위반율이 1%에서 최대 2.2%로 늘어나므로, 본 연구의 "꼬리는 불리하지 않다"는 결과를 극단 위험에 그대로 적용해서는 안 된다.
2. 표본 범위가 제한적이다. 다음 날 예측만 다루었으므로 여러 날 앞 예측에서는 오차 누적과 군집의 영향이 다르게 나타날 수 있다. 대상은 2017년 기준 미국 · 한국 대형주 10종목이며(미국은 기준 연구 재현을 위해, 한국은 시가총액 순위로 선정), 소형주, 다른 자산(채권, 환율, 암호화폐), 다른 시장으로의 일반화는 확인하지 않았다. 합성 데이터의 단계값도 이 10종목에서 측정했으므로 특성이 더 극단적인 자산에서는 효과가 더 클 수 있고, 특성 간 상호작용은 실제 데이터로 간접 확인하는 데 그쳤다.
3. 평가한 모델의 크기와 종류가 제한적이다. Chronos-T5는 계산 시간 규칙에 따라 large 대신 base를 사용하였고, Moirai-2.0은 small 크기만 평가하였다. 미세조정이나 금융 데이터로 사전학습한 모델은 다루지 않았다.
4. 사후보정의 적용 범위가 구간 양 끝에 한정된다. 보정은 80% 구간의 양 끝만 조정하므로 분포 전체의 정확도를 높이지 않으며, 위반이 몰려 오는 문제(한 달 · 가격 조건)는 고치지 못하였다. 또한 사후 배율로 일괄 확대한 대조군보다 폭 효율이 낮았다.
5. 경제적 가치 분석은 탐색적이다. 사전등록 밖의 분석이며, 전날 종가 체결과 단순한 비용 가정을 사용하였고, 표본 기간이 강세장을 포함한다.

7.4 향후 연구

1. 극단 분위수(1%, 5%)를 내는 모델과 설정에서 꼬리 특성의 영향 재검증
2. 여러 날 앞 예측과 다른 자산군으로의 확장
3. Chronos-T5 수익률 입력의 구간 붕괴 원인(입력 크기 조정 · 구간화 방식) 규명
4. 보정의 폭 효율 개선: 갱신 속도(γ)의 적응적 조정, 변동 크기에 따른 조건부 보정, 위반 몰림을 줄이는 방법
5. 금융 데이터로 미세조정 · 사전학습한 모델과의 비교(Rahimikia 외, 2025의 방향)

7.5 맺음말

금융 분야에서 새로운 예측 모델을 도입할 때는 점 예측의 정확도에 앞서 예측구간이 명목 신뢰수준을 충족하는지를 검증해야 한다. 본 연구의 결과에 따르면 TSFM 예측구간의 신뢰성은 모델 자체의 복잡도보다 입력 설정과 사후보정 여부에 의해 좌우된다. 본 연구의 의의는 TSFM이 기존의 단순 모형보다 낫다는 것을 보이는 데 있지 않고, TSFM을 금융 위험 측정에 쓸 때 어떤 설정 오류가 생길 수 있는지(Chronos-T5 수익률 입력의 실제 커버리지 17~18%)와 이를 모델을 재학습하지 않고 어떻게 미리 점검하고 교정하는지를 보인 데 있다. 이 점검과 보정은 모델 구조와 무관하므로 앞으로 공개될 모델에도 그대로 적용할 수 있다. 따라서 사전학습 시계열 모델의 예측구간을 실무 위험 관리에 활용할 때에는 입력 설정에 대한 사전 점검과 온라인 사후보정을 필수적인 절차로 결합해야 한다.

참고문헌

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research* (10/2024). arXiv:2403.07815.

Ansari, A. F., Shchur, O., Küken, J., Auer, A., Han, B., Mercado, P., et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821.

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327.

Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841-862.

Cont, R. (2001). Empirical properties of asset returns: Stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223-236.

Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. arXiv:2310.10688.

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987-1007.

Gibbs, I., & Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems*, 34.

Gneiting, T., Balabdaoui, F., & Raftery, A. E. (2007). Probabilistic forecasts, calibration and sharpness. *Journal of the Royal Statistical Society: Series B*, 69(2), 243-268.

Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359-378.

Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357-384.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65-70.

Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73-84.

Liu, C., Aksu, T., Liu, J., Liu, X., Yan, H., Pham, Q., et al. (2025). Moirai 2.0: When less is more for time series forecasting. arXiv:2511.11698.

Noguer i Alonso, M., & Franklin, R. P. (2026). Pretrained time-series foundation models for financial return forecasting. arXiv:2606.27100.

Rahimikia, E., Ni, H., & Wang, W. (2025). Re(Visiting) time series foundation models in finance. arXiv:2511.18578.

Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems*, 32.

Sun, J., Koa, K. J. L., Ni, R., Liu, Y., Chen, H., & Huang, K.-W. (2026). FinStressTS: A parametric synthetic benchmark for time-series forecasting in finance. *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '26)*. arXiv:2606.03184.

Wang, T., Ennadir, S., Pertoft, J., Zarzar Gandler, G., Cao, L., Senane, Z., et al. (2025). Frequency matters: When time series foundation models fail under spectral shift. NeurIPS 2025 Workshop on Recent Advances in Time Series Foundation Models. arXiv:2511.05619.

Woo, G., Liu, C., Kumar, A., Xiong, C., Savarese, S., & Sahoo, D. (2024). Unified training of universal time series forecasting transformers. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. arXiv:2402.02592.

(소프트웨어) chronos-forecasting 2.3.2, timesfm 3.0.2, uni2ts 2.0.0, arch 8.0.0. 데이터: yfinance, FinanceDataReader, FinanceData/marcap.

부록 A. 사전등록 및 재현 정보

A.1 사전등록 동결과 이탈 기록

- 일정: 설계 확정 · 단계값 측정 · 사전 시험(2026-10-13) → 동결 커밋 8f55c57(2026-10-14 01:43 KST) → 본 실행(GPU 추론, 01:44~07:06, 약 5.4 시간) → 독립 검산 및 분석.
- 동결 후의 변경은 사전등록 프로토콜의 이탈 기록 절차(변경 사유 기록과 새 커밋)로만 허용하였다.
- 동결 전 사전 시험: 실제 GPU 환경과 같은 패키지 버전으로 전체 규모를 시험하였다. 이때 TSFM 대신 더미(dummy) 모델을 사용하였으나, 기준 모형(RW, GARCH-t)은 실제 모델이므로 실제 주가에 대한 기준 모형 결과(커버리지 등)가 시험 출력에 함께 산출되었다. 이를 본 뒤 설정과 코드는 바꾸지 않았고, 본 실행에서 같은 값을 다시 계산하였다.
- 사후 발견: GARCH-t 합성 2 건(전환크기 L3 계열 79 의 66 일째, 꼬리 L2 계열 86 의 64 일째)이 사전 대체 규칙(유한값 아님, 분산 ≤ 0, ν ≤ 2)에 걸리지 않는 비정상 값을 냈다. 민감도는 6.5 절.

A.2 실행 환경 및 패키지 버전

- 실행 환경: Python 3.11.17, PyTorch 2.5.1(CUDA 12.1), NVIDIA RTX 3080 10GB, chronos-forecasting 2.3.2, timesfm 3.0.2, uni2ts 2.0.0, arch 8.0.0, numpy 1.26.4, pandas 2.1.4, scipy 1.11.4, pyarrow 20.0.0

부록 B. 특성 강도 비교(L5 − L3)

제4장 표 4-2와 같은 방식으로, 각 특성을 실측 범위의 가장 약한 값(L3)에서 가장 강한 값(L5)으로 바꿨을 때의 커버리지 변화(%p)를 제시한다. 표시는 표 4-2와 같다(▼▽ 가설 방향 유의, ▲△ 반대 방향 유의, 큰 기호는 2%p 이상, Holm 보정 16개 묶음). 기준 모형은 서술용이다.

표 B-1. 특성을 L3에서 L5로 강하게 설정했을 때의 커버리지 변화 (L5 − L3, %p)

모델	조건	H1 군집	H2 꼬리	H3a 전환빈도	H3b 전환크기
Chronos-T5	한 달 · 수익률	−0.6	+1.2△	+0.7	0.0
Chronos-T5	한 달 · 가격	−0.5	+1.7△	+2.1▲	+0.1
Chronos-T5	1년 · 수익률	+1.3	+0.4	−0.4	+0.7
Chronos-T5	1년 · 가격	−0.5	+0.6	+2.1▲	−0.1
Chronos-2	한 달 · 수익률	−0.3	+0.1	+0.6	0.0
Chronos-2	한 달 · 가격	−0.1	+1.1△	+1.2△	0.0
Chronos-2	1년 · 수익률	+0.2	+1.4△	+1.9△	+0.1
Chronos-2	1년 · 가격	−0.9	+1.7△	+2.4	+0.1
TimesFM-2.5	한 달 · 수익률	−0.2	+0.5	+1.4△	−0.2
TimesFM-2.5	한 달 · 가격	−0.3	+0.5	+1.3	−0.1
TimesFM-2.5	1년 · 수익률	+0.2	−1.0	−0.4	−1.2▽
TimesFM-2.5	1년 · 가격	+0.2	+0.1	+0.4	−0.5
Moirai-2	한 달 · 수익률	+0.1	+1.1△	+1.7△	+0.3
Moirai-2	한 달 · 가격	−1.2▽	+1.5△	+2.6▲	−0.1
Moirai-2	1년 · 수익률	+1.2	+0.1	+0.6	−0.3
Moirai-2	1년 · 가격	−0.4	+1.0△	+1.1	−0.3
과거변동(RW)	한 달 · 수익률	−0.1	+2.5	+3.2	+0.1
과거변동(RW)	1년 · 수익률	+2.3	+4.1	+1.9	+2.3
GARCH-t	1년 · 수익률	−0.2	+0.2	+1.3	+0.1

주: 2%p 이상이지만 기호가 없는 칸(예: Chronos-2 1년 · 가격 H3a +2.4, Holm 보정 $p = 0.060$)은 보정 후 유의하지 않은 경우이다.

부록 C. 종목별 실제 커버리지

표 5-1의 보정 전 커버리지를 종목별로 구분하여 제시한다(%, 종목당 채점 1,740~1,800건). 표 C-1은 미국 5종목, 표 C-2는 한국 5종목이다.

표 C-1. 미국 종목별 보정 전 커버리지 (%)

모델	조건	AAPL	AMZN	GOOG	JPM	META
Chronos-T5	한 달 · 수익률	13.5	14.5	14.9	15.5	14.2
Chronos-T5	한 달 · 가격	76.7	75.8	75.9	76.9	76.7
Chronos-T5	1년 · 수익률	14.4	15.3	16.9	15.8	15.7
Chronos-T5	1년 · 가격	75.9	76.0	78.0	77.3	75.8
Chronos-2	한 달 · 수익률	82.2	82.1	81.6	82.2	82.1
Chronos-2	한 달 · 가격	82.1	80.9	81.6	81.4	81.7
Chronos-2	1년 · 수익률	78.0	80.1	79.6	78.8	79.2
Chronos-2	1년 · 가격	78.4	80.1	80.7	79.7	80.3
TimesFM-2.5	한 달 · 수익률	77.9	78.4	77.8	78.5	78.4
TimesFM-2.5	한 달 · 가격	78.1	77.7	78.3	77.6	77.2
TimesFM-2.5	1년 · 수익률	75.6	77.5	77.1	76.3	75.4
TimesFM-2.5	1년 · 가격	86.2	88.4	87.3	87.3	86.0
Moirai-2	한 달 · 수익률	77.9	76.3	77.6	77.8	77.1
Moirai-2	한 달 · 가격	79.7	78.8	78.7	79.8	78.9
Moirai-2	1년 · 수익률	78.6	81.1	80.9	79.7	80.2
Moirai-2	1년 · 가격	82.8	83.3	83.8	83.3	81.9
과거변동(RW)	한 달 · 수익률	80.1	79.3	80.2	80.3	79.8
과거변동(RW)	1년 · 수익률	83.6	84.6	84.1	84.4	85.7
GARCH-t	1년 · 수익률	78.7	79.2	79.1	77.4	78.5

표 C-2. 한국 종목별 보정 전 커버리지 (%)

모델	조건	삼성전자	SK하이닉스	현대차	한국전력	현대모비스
Chronos-T5	한 달 · 수익률	19.9	16.0	22.2	19.0	19.3
Chronos-T5	한 달 · 가격	74.4	76.1	77.7	76.8	77.6
Chronos-T5	1년 · 수익률	16.8	15.1	26.1	18.3	21.9
Chronos-T5	1년 · 가격	75.6	74.0	77.2	76.8	75.3
Chronos-2	한 달 · 수익률	81.3	82.2	81.0	81.7	81.7
Chronos-2	한 달 · 가격	79.6	81.8	81.4	79.7	80.2
Chronos-2	1년 · 수익률	79.4	78.9	79.3	79.4	78.7
Chronos-2	1년 · 가격	80.9	79.4	80.9	80.9	78.3
TimesFM-2.5	한 달 · 수익률	78.4	77.8	78.2	78.0	78.3
TimesFM-2.5	한 달 · 가격	77.1	77.7	78.4	77.9	78.0
TimesFM-2.5	1년 · 수익률	79.2	79.3	77.5	76.8	77.9
TimesFM-2.5	1년 · 가격	87.6	87.2	89.1	89.2	88.6
Moirai-2	한 달 · 수익률	76.3	77.5	76.6	76.8	76.9
Moirai-2	한 달 · 가격	77.4	78.3	78.7	77.9	78.6
Moirai-2	1년 · 수익률	80.3	79.7	79.4	79.5	79.1
Moirai-2	1년 · 가격	81.4	81.7	81.0	80.3	81.7
과거변동(RW)	한 달 · 수익률	79.0	78.7	79.8	79.7	79.2
과거변동(RW)	1년 · 수익률	81.1	79.9	81.8	83.2	81.7
GARCH-t	1년 · 수익률	79.1	78.1	78.2	78.7	77.3

ABSTRACT

Prediction Intervals of Pretrained Time Series Foundation Models for Financial Returns: Sources of Error and Training-Free Post-hoc Calibration

Kim, Seungmin
Dept. of Artificial Intelligence Convergence
Graduate School of Applied Artificial Intelligence
Hanyang University

Time series foundation models (TSFMs) produce prediction intervals without task-specific training, but whether these intervals keep their nominal coverage on financial returns has not been systematically tested. This thesis diagnoses whether miscoverage of TSFM 80% intervals stems from financial stylized facts or from the model and its usage settings, evaluates performance on real equities, and tests whether a training-free post-hoc calibration can restore coverage.

We generate 17 synthetic scenarios whose feature strengths (volatility clustering, heavy tails, regime-switching frequency and magnitude) are calibrated to ten U.S. and Korean large-cap stocks, varying one feature at a time under common random numbers. Four TSFMs (Chronos-T5, Chronos-2, TimesFM-2.5, Moirai-2.0) are evaluated on next-day log returns under four settings (21- or 252-day context; return or price input), and the same protocol is applied to the ten stocks over 2017-2026 (24,132 forecasts). All settings and tests were preregistered.

Even on feature-free data, TSFM coverage already ranged from 14% to 88% depending on model and setting, while raising feature strength to the

strongest observed level moved coverage mostly within 3 percentage points. Only volatility clustering reduced coverage in some settings; heavy tails and frequent regime switching increased it, a consequence of variance-based 80% intervals under leptokurtic distributions. Real-stock coverage matched feature-free synthetic coverage within 1.0 point on average (excluding the two collapsed Chronos-T5 return-input settings; 1.2 points across all 19). On real stocks, quantile loss was larger than that of a historical-volatility Gaussian benchmark in 13 of 16 settings. Adaptive conformal quantile calibration (ACI-CQR) restored coverage to 80% in all 340 synthetic and 19 real model-settings, at the cost of intervals 6-48% wider than the oracle. In exploratory analyses, calibrated intervals also restored the intended risk levels in a volatility-targeting strategy and in VaR backtests.

These results show that the reliability of TSFM intervals on financial returns is governed by model and input settings rather than by stylized facts, and that synthetic experiments calibrated to real markets can anticipate real-stock coverage. Distributional accuracy did not exceed the simple benchmark, reaching parity only in the best settings (one-year return input for the three models other than Chronos-T5). Current TSFMs are therefore better used not as return forecasters but as risk-measurement tools, after checking input settings and applying training-free post-hoc calibration.

Keywords: time series foundation model, prediction interval, coverage, controlled synthetic experiment, conformal prediction, stock returns